Lumina Retail

Datos conectados.

Operación sincronizada.

Anticipar la demanda. Optimizar el inventario.
Acelerar la entrega.

RetailSmart Global
2026

Control de versiones

Versión	Hito	Actualización
1.0	Propuesta inicial de solución	Diagnóstico del negocio, alcance de Lumina Retail y arquitectura objetivo.
2.0	Propuesta integral consolidada	Se consolidan arquitectura y flujos E2E, contratos de datos, implementación reproducible y estimación de costos GCP para evaluación gerencial.

Índice general

Control de versiones **i**

1 Resumen ejecutivo **1**
1.1 Problema de negocio y consecuencias operativas . . . 2
1.2 Solución propuesta y alcance inicial . . . 2
1.3 Beneficios esperados y decisiones de arquitectura . . . 2

2 Contexto empresarial y diagnóstico **3**
2.1 RetailSmart Global y la iniciativa Lumina Retail . . . 4
2.2 Supuestos y frontera funcional de Lumina . . . 4
2.3 Visión de Lumina Retail . . . 4
2.4 Operación actual y proceso de extremo a extremo . . . 4
2.5 Fragmentación de inventarios, silos y congestión logística . . . 5
2.6 Relación entre problemas, causas e impactos . . . 6

3 Objetivos, alcance y criterios de éxito **7**
3.1 Objetivo general y objetivos específicos . . . 8
3.2 Verticales y decisiones de negocio . . . 8
3.3 Requisitos funcionales y atributos de calidad . . . 9
3.4 Indicadores y método de medición . . . 9
3.5 Supuestos, restricciones, dependencias y exclusiones . . . 9

4 Estrategia de datos y escenarios de negocio **11**
4.1 Inventario y clasificación de fuentes . . . 12
4.2 Evaluación de datasets públicos de referencia . . . 12
4.3 Estrategia híbrida con predominio sintético . . . 12
4.4 Correspondencia entre fuentes, entidades y verticales . . . 12
4.5 Escenarios controlados . . . 13
4.6 Claves y reglas de correspondencia . . . 13

5 Arquitectura de Solución de extremo a extremo **14**
5.1 Principios y decisiones de diseño . . . 15
5.2 Vista de negocio y relación con las verticales . . . 15
5.3 Vista de aplicaciones y servicios de datos . . . 16
5.4 Vista tecnológica y correspondencia con GCP . . . 16
5.5 Recorrido por ingesta, procesamiento, almacenamiento y exposición . . . 17
5.6 Topología de red y conectividad . . . 18
5.7 Trazabilidad entre elementos, componentes y requisitos . . . 18

6 Diseño detallado de ingesta e integración **19**
6.1 Criterios para seleccionar batch o streaming . . . 20
6.2 Flujo streaming y contratos de eventos . . . 20
6.3 Flujo batch y fuentes históricas . . . 20
6.4 Validación, metadatos y versionamiento de esquemas . . . 20
6.5 Duplicados, eventos tardíos, errores y reprocesamiento . . . 21
6.6 Frecuencias, latencias y volúmenes estimados . . . 22

7 Diseño de almacenamiento y organización de datos **23**
7.1 Justificación de los motores de almacenamiento . . . 24
7.2 Responsabilidad de Bronze, Silver y Gold . . . 24
7.3 Formatos, particionamiento y organización física . . . 24
7.4 Retención y ciclo de vida . . . 24
7.5 Modelo conceptual y estructuras para consumo . . . 25
7.6 Integración del histórico con eventos operativos . . . 25

8 Selección y justificación tecnológica **26**
8.1 Criterios y alternativas consideradas . . . 27
8.2 Sustento de los componentes seleccionados . . . 27
8.3 Tecnologías abiertas y servicios administrados de GCP . . . 28
8.4 Compromisos de portabilidad, rendimiento y operación . . . 28
8.5 Registro de decisiones de arquitectura . . . 29

9 Escalabilidad y rendimiento **30**
9.1 Volumetría y carga normal . . . 31
9.2 Black Friday y Cyber Monday . . . 31
9.3 Capacidad y escalamiento por capa . . . 31
9.4 Cuellos de botella y saturación . . . 31
9.5 Objetivos y pruebas de rendimiento . . . 31

10 Justificación económica y estimación de costos **33**

11 Fiabilidad, alta disponibilidad y recuperación **35**
11.1 Escenarios de falla y consecuencias operativas . . . 36
11.2 Indisponibilidad del inventario de una tienda . . . 36
11.3 Tolerancia a fallos y recuperación del procesamiento . . . 36
11.4 Objetivos RTO y RPO propuestos . . . 37
11.5 DRP y procedimiento de validación . . . 37

12 Gobierno, calidad y seguridad de datos **39**
12.1 Responsables y clasificación . . . 40
12.2 Catálogo, diccionario y metadatos . . . 40
12.3 Linaje desde la fuente hasta el consumo . . . 40
12.4 Reglas de calidad e incumplimientos . . . 40
12.5 Identidades, permisos y mínimo privilegio . . . 41
12.6 Cifrado y protección de datos sensibles . . . 42
12.7 Auditoría y trazabilidad . . . 42
12.8 Nomenclatura y catálogo de recursos . . . 42

13 Plan de implementación y validación **43**
13.1 Fase 1: habilitar el flujo prioritario . . . 44
13.2 Fase 2: integrar históricos y productos de información . . . 44
13.3 Fase 3: activar consumo operacional . . . 44
13.4 Dependencias y criterios de avance . . . 44
13.5 Experimentos contra el escenario base . . . 45

14 Conclusiones y próximos pasos **46**
14.1 Correspondencia entre solución y problemática . . . 47
14.2 Decisiones adoptadas, riesgos y asuntos pendientes . . . 47
14.3 Prioridades para la siguiente etapa . . . 47

Fuentes técnicas y de datos **48**

Anexos **49**

A Matriz de fuentes, verticales, componentes e indicadores **50**

B Contratos de eventos y diccionario de datos **51**
B.1 Perfil semántico mínimo propuesto . . . 51
B.2 Ejemplo ilustrativo de evento de inventario . . . 51

C Catálogo y nomenclatura de recursos **52**
C.1 Convenciones de identificación . . . 52
C.2 Labels y atributos . . . 52

D Detalle del costeo GCP **53**

E Vistas de la Arquitectura de Solución **54**

Índice de figuras

1 Atención de pedidos en la situación actual . . . 5
2 El pedido que da vueltas . . . 5
3 Capacidades de negocio, resultados esperados e indicadores propuestos. . . . 9
4 De la alerta al valor . . . 10
5 Dos entradas, una operación . . . 12
6 Uso independiente de las fuentes y validación de equivalencias del escenario. . . . 13
7 Arquitectura final aprobada de Lumina Retail, exportada desde el modelo ArchiMate canónico. . . . 15
8 Atención inteligente de pedidos propuesta . . . 16
9 Síntesis vectorial de la arquitectura de datos . . . 17
10 Vista de red de la arquitectura objetivo de Lumina Retail. . . . 18
11 Recorrido lógico de un evento: preservación, validación, identidad, vigencia y reproceso. . . 22
12 Tres mesas de trabajo . . . 24
13 Entidades de negocio y relaciones conceptuales descritas en el diseño aprobado. . . . 25
14 Secuencia de actualización del diseño antes de modificar la implementación. . . . 29
15 Escenarios nominal y pico propuestos para validar el comportamiento del flujo. . . . 32
16 La tienda perdió la señal . . . 36
17 Maqueta conceptual para comunicar vigencia y degradación; no representa una aplicación implementada. . . . 37
18 Objetivos RTO y RPO, condicionados a una copia externa habilitada y probada. . . . 38
19 El pasaporte del dato . . . 40
20 Fases de implementación y validación mediante evidencia de funcionamiento. . . . 45
21 Vista contextual AS-IS de extremo a extremo . . . 54
22 Vista contextual TO-BE de extremo a extremo . . . 55
23 Vista completa de atención de pedidos AS-IS . . . 56
24 Vista completa de atención inteligente de pedidos TO-BE . . . 57
25 Relación entre aplicaciones y procesos AS-IS . . . 58
26 Relación entre aplicaciones y procesos TO-BE . . . 59
27 Vista macro de componentes e integración . . . 60
28 Modelo vigente de arquitectura de solución, exportado desde el archivo ArchiMate canónico. 61

Índice de tablas

1 Problemas consolidados, aporte de Lumina y responsabilidad operacional . . . 6
2 Alineamiento entre problemas de negocio y verticales de Lumina . . . 8
3 Tipo de procesamiento y pregunta de negocio . . . 8
4 Utilidad y límites de los datasets públicos . . . 12
5 Escenarios de validación y respuesta esperada . . . 13
6 Correspondencia entre componentes de solución y servicios . . . 16
7 Eventos de entrada y uso principal . . . 20
8 Responsabilidades de las capas de datos . . . 24
9 Alternativas tecnológicas y compromisos . . . 27
10 Justificación técnica de los servicios seleccionados . . . 28
11 Decisiones y condiciones de aceptación . . . 29
12 Controles de capacidad por capa . . . 31
13 Escenarios de costo de infraestructura GCP . . . 34
14 Supuestos de dimensionamiento utilizados en el visor . . . 34
15 Objetivos iniciales de recuperación . . . 37
16 Identidades de ejecución y alcance de permisos IAM . . . 41
17 Condiciones de avance por fase . . . 44
18 Experimentos y reglas para decidir . . . 45
19 Trazabilidad de las fuentes al resultado . . . 50
20 Diccionario semántico de trazabilidad . . . 51
21 Catálogo lógico inicial para revisión . . . 52
22 Matriz resumida de servicios y supuestos de costeo . . . 53

Capítulo

1
Resumen ejecutivo

1.1 Problema de negocio y consecuencias operativas

RetailSmart Global opera con tiendas físicas y canales de e-commerce sobre una red amplia de tiendas y almacenes. El problema no es únicamente disponer de stock o vender por distintos canales, sino anticipar dónde y cuándo puede agotarse el inventario, si dicho inventario está cerca de la demanda, cuándo la capacidad operativa puede saturarse, cómo se comporta el cliente entre unidades y canales y qué activos pueden degradarse antes de afectar la operación.

Estas brechas se manifiestan en mayores costos de última milla, retrasos durante campañas de alta demanda, quiebres de inventario, decisiones aisladas entre unidades y mantenimiento reactivo. La plataforma no pretende corregir fallas transaccionales del ERP, OMS, WMS, TMS, CRM o sistemas de mantenimiento, sino reducir la demora entre la generación de datos y la toma de decisiones.

1.2 Solución propuesta y alcance inicial

Proponemos la Plataforma de Datos RetailSmart como soporte de Lumina Retail, entendida como una capa analítica que integra información de ventas, pedidos, inventario, logística, clientes, interacción digital y telemetría. Lumina conserva histórico, combina señales recientes y genera alertas, análisis, predicciones y recomendaciones para apoyar a los responsables operacionales. Las predicciones corresponden a modelos analíticos por lotes; no se incorpora un agente autónomo o conversacional. Agent Platform se reserva para una eventual capacidad basada en agentes y no se presenta como un servicio desplegado en esta solución.

El principio rector es: **Lumina observa, integra, analiza, anticipa y recomienda; el ecosistema operacional decide y ejecuta**. Por tanto, la solución no sustituye la reserva transaccional de stock, el procesamiento del pedido, el picking, el despacho, el pago, la identidad maestra del cliente ni el mantenimiento físico de activos.

1.3 Beneficios esperados y decisiones de arquitectura

El beneficio depende de convertir datos fragmentados en inteligencia accionable. Una señal de caída acelerada de stock puede activar una revisión de reposición; una predicción geográfica puede sustentar el reposicionamiento de inventario; una alerta de saturación puede permitir preparar capacidad; una vista analítica de cliente puede mejorar la comprensión omnicanal; y una anomalía de telemetría puede priorizar una inspección preventiva.

Las decisiones principales son integrar mediante claves gobernadas, combinar streaming, batch, analítica y capacidades predictivas según la pregunta de negocio, separar Bronze, Silver y Gold, preservar la autoridad de los sistemas operacionales y utilizar servicios gestionados de GCP con una excepción explícita frente a la preferencia por código abierto. El avance se condiciona a datos conciliados, responsables de actuación y evidencia medible de valor.

Capítulo

2

Contexto empresarial y diagnóstico

2.1 RetailSmart Global y la iniciativa Lumina Retail

El contexto de negocio de RetailSmart comprende más de nueve millones de clientes activos, ocho regiones logísticas y doce unidades de negocio. La iniciativa Unifica-Retail establece Lumina Retail para aprovechar conjuntamente canales, inventario y activos de distribución. Conviven compras físicas que requieren asistencia y compras móviles que demandan rapidez; ambas necesitan información confiable y oportuna para anticipar demanda, disponibilidad y capacidad.

La lectura adoptada para este informe distingue la visión empresarial completa de RetailSmart de la responsabilidad específica de la plataforma de datos. Lumina no se considera un nuevo núcleo transaccional, sino una capacidad transversal de inteligencia que consume datos del ecosistema operativo y devuelve señales, análisis, predicciones y recomendaciones.

2.2 Supuestos y frontera funcional de Lumina

Se asume que RetailSmart dispone, o debe disponer, de sistemas operacionales responsables de pedidos, inventario, reservas, preparación, despacho, entrega, pagos, logística, clientes y mantenimiento. Dichos sistemas continúan siendo la autoridad transaccional y una venta debe poder completarse aunque Lumina esté temporalmente indisponible.

El sistema operacional de inventario es la fuente de verdad del stock actual y de las reservas. De igual forma, se recomienda una capacidad empresarial de Master Data Management (MDM) para resolver identidad canónica, duplicados y atributos maestros de cliente. Lumina consume estas fuentes para análisis, pero no sustituye sus responsabilidades.

> **Lumina ayuda a decidir mejor qué hacer; los sistemas operacionales realizan la acción.**

2.3 Visión de Lumina Retail

La visión se interpreta como la construcción de una capa analítica de datos que conecta demanda, inventario, capacidad logística, comportamiento del cliente y condición de activos. Lumina puede identificar desde qué ubicación resulta más conveniente atender una demanda, detectar oportunidades de agrupación o priorización, comparar alternativas de atención y anticipar riesgos de quiebre, saturación o degradación.

Las funcionalidades de reserva de inventario, ejecución de picking, asignación de transporte, seguimiento transaccional del pedido y procesamiento del pago permanecen en los sistemas operacionales. En consecuencia, la compra bajo demanda, la optimización de pedidos y la omnicanalidad se consideran experiencias de negocio habilitadas por inteligencia de Lumina, no acciones ejecutadas directamente por la plataforma.

2.4 Operación actual y proceso de extremo a extremo

El proceso comprende captura de demanda, validación de inventario, preparación, despacho, entrega y seguimiento operativo. Los canales, el sistema de pedidos, el ERP, los sistemas de almacén y la logística ejecutan esas actividades. Lumina se ubica fuera de la ruta transaccional obligatoria: recibe datos y eventos de la operación, los integra y produce inteligencia que puede ser consumida por los responsables y aplicaciones correspondientes.

La información parcial entre etapas y los reportes diferidos limitan hoy la capacidad de anticipar problemas. La figura 1 ubica estas limitaciones en el recorrido del pedido.

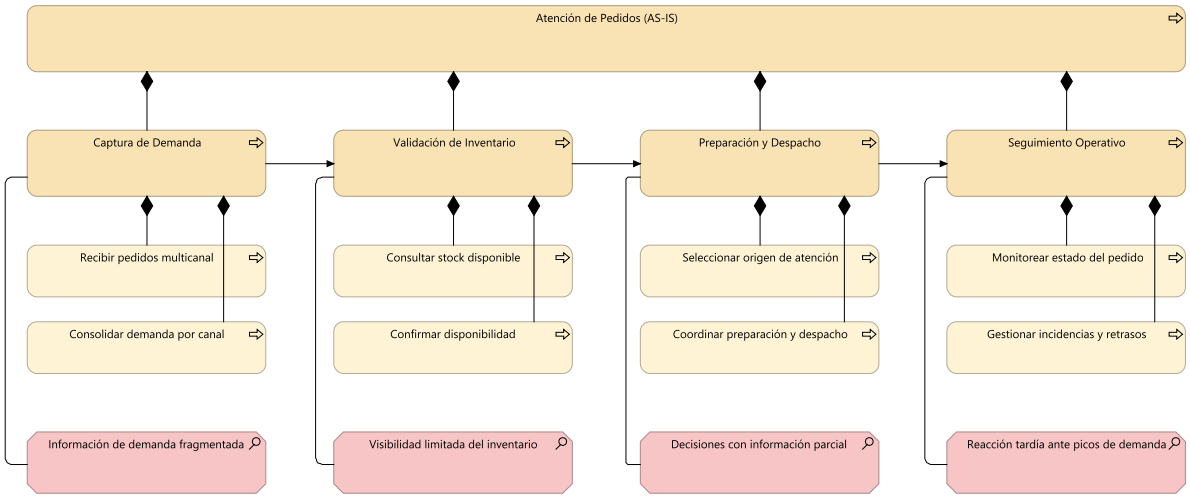

Figura 1: Atención de pedidos en la situación actual.
Fuente: Modelo de solución elaborado por el equipo [7].

2.5 Fragmentación de inventarios, silos y congestión logística

La problemática se consolida en cinco frentes. Primero, conocer el stock actual no permite anticipar dónde y cuándo se agotará. Segundo, disponer de inventario global no garantiza que esté cerca de las zonas donde se concentrará la demanda. Tercero, durante campañas como Black Friday la demanda puede superar la capacidad de preparación y distribución antes de que la organización reaccione. Cuarto, las unidades y canales pueden conocer al cliente de forma fragmentada aun cuando exista una identidad maestra. Quinto, la telemetría puede informar que un activo funciona ahora sin anticipar su degradación.

La plataforma debe reducir estas brechas de información mediante histórico, señales recientes, análisis y predicción; no puede corregir por sí sola falta física de stock, insuficiencia transaccional, errores de reserva, carencia de capacidad logística o fallas de ejecución.

Figura 2: Inventarios e información aislados dificultan atender un pedido aun cuando el producto existe en la red.

2.6 Relación entre problemas, causas e impactos

Tabla 1: Problemas consolidados, aporte de Lumina y responsabilidad operacional

Problema	Frase resumen	Aporte de Lumina	Ecosistema operacional
P1. Riesgo de quiebre	Sé cuánto stock tengo, pero no dónde ni cuándo se va a agotar.	Predicción de consumo, riesgo de quiebre, alertas y recomendaciones.	Mantener stock transaccional, reservas, movimientos y reposición.
P2. Desalineación geográfica	Sé dónde está mi stock, pero no si está cerca de donde se concentrará la demanda.	Predicción geográfica y recomendaciones de posicionamiento.	Ejecutar transferencias, abastecimiento, asignación logística y despacho.
P3. Saturación operativa	Sé que la demanda está creciendo, pero no cuándo va a superar mi capacidad operativa.	Predicción de saturación, presión operacional y cuellos de botella.	Escalar, priorizar y reasignar recursos de operación.
P4. Comportamiento fragmentado	Sé quién es el cliente, pero no entiendo su comportamiento completo entre unidades y canales.	Vista analítica transversal, patrones, segmentos y tendencias.	MDM, CRM y sistemas fuente mantienen identidad y operación.
P5. Riesgo de falla de activos	Sé que el equipo funciona ahora, pero no cuándo empezará a degradarse o fallar.	Anomalías, riesgo de falla y recomendación de mantenimiento.	Inspeccionar, mantener, reparar y controlar físicamente activos.

Estos problemas forman una cadena coherente: anticipar quiebre, verificar proximidad del inventario a la demanda, estimar si la operación absorberá esa demanda, comprender el comportamiento que la origina y asegurar que la infraestructura física pueda sostenerla. El diagnóstico identifica mecanismos de impacto, sin atribuir a Lumina capacidades transaccionales ni mejoras todavía no observadas.

Capítulo

3

Objetivos, alcance y criterios de éxito

3.1 Objetivo general y objetivos específicos

El objetivo general es mejorar la calidad y oportunidad de las decisiones sobre demanda, inventario, capacidad, cliente y activos mediante una plataforma de datos que integre información heterogénea y genere análisis, predicciones, alertas y recomendaciones.

Los objetivos específicos son: anticipar riesgo de quiebre de stock; estimar la demanda por zona para apoyar el posicionamiento de inventario; detectar riesgo de saturación operativa; consolidar una visión analítica del comportamiento del cliente a partir de una identidad confiable; y anticipar degradación de activos. El éxito requiere una secuencia completa desde el dato hasta una decisión registrada, sin trasladar a la plataforma la ejecución transaccional.

3.2 Verticales y decisiones de negocio

Las cuatro verticales se mantienen, pero se interpretan como capacidades complementarias. No existe una relación de uno a uno entre problema y vertical: un mismo problema puede requerir señales recientes, históricos, analítica y predicción.

Tabla 2: Alineamiento entre problemas de negocio y verticales de Lumina

Problema	V1. Decisiones en tiempo real	V2. Planes diarios de inventario	V3. Informes operativos	V4. Mantenimiento proactivo
P1. Riesgo de quiebre	Apoya con señales recientes de stock y demanda.	**Principal**: predicción de quiebre y necesidad estimada.	Mide quiebres, disponibilidad y evolución.	–
P2. Stock lejos de demanda	Apoya con señales de demanda y ubicación.	**Principal**: predicción geográfica y posicionamiento.	Mide costo, distancia y tiempos de entrega.	–
P3. Saturación operativa	**Principal**: detecta presión y cambios rápidos.	Apoya con previsiones de campañas y demanda.	**Principal**: analiza capacidad, tiempos y costos.	Apoya si una degradación reduce capacidad.
P4. Comportamiento fragmentado	Apoya con clics e interacción reciente.	Puede enriquecer forecast de demanda.	**Principal**: análisis transversal por cliente y canal.	–
P5. Degradación de activos	Apoya con telemetría reciente.	–	Mide desempeño e incidentes históricos.	**Principal**: anomalías y mantenimiento predictivo.

Tabla 3: Tipo de procesamiento y pregunta de negocio

Tipo	Pregunta que responde	Horizonte	Ejemplo en Lumina
Streaming	¿Qué está ocurriendo ahora?	Segundos/minutos	Stock cayendo, demanda creciendo, telemetría anómala.
Batch	¿Qué información debe procesarse de forma consolidada?	Horas/días	Históricos de ventas, inventario y preparación de datasets.
Analítico / OLAP	¿Cómo estamos funcionando?	Histórico/consolidado	Costos, tiempos, conversión y utilización.
Predictivo	¿Qué probablemente ocurrirá?	Futuro	Demanda, quiebre, saturación y falla.
Prescriptivo	¿Qué convendría hacer?	Futuro/decisión	Reposición, redistribución, priorización o alternativa recomendada.

La capacidad prescriptiva no constituye una quinta vertical; representa una evolución de las capacidades analíticas y predictivas cuando la salida es una recomendación. La ejecución continúa en el ecosistema operacional.

La figura 3 resume las capacidades, resultados e indicadores propuestos.

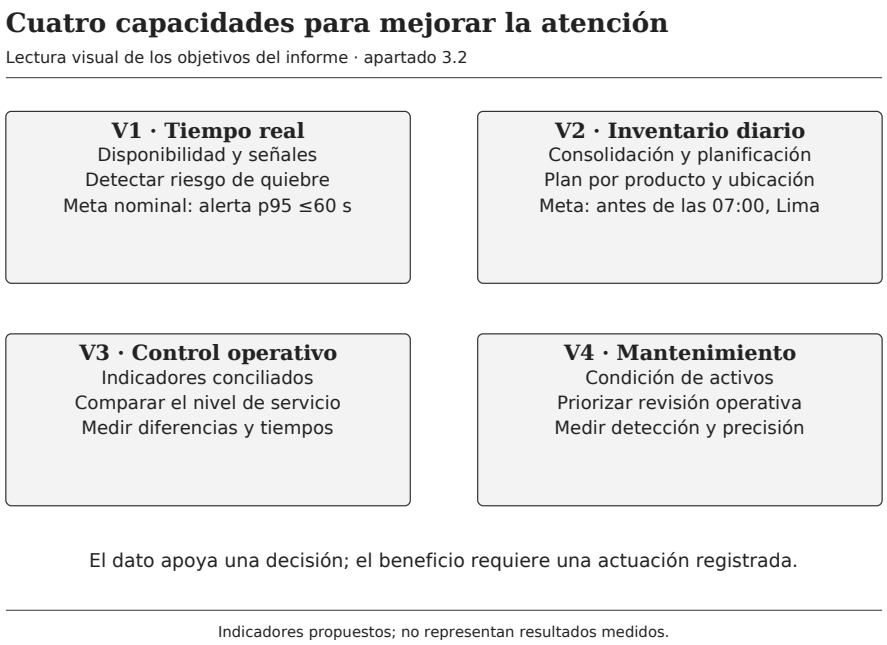

Figura 3: Capacidades de negocio, resultados esperados e indicadores propuestos.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

3.3 Requisitos funcionales y atributos de calidad

La solución debe integrar eventos e históricos, relacionar entidades, conservar originales, generar señales y exponer resultados analíticos o predictivos. Debe permitir reproceso, controlar accesos, mostrar vigencia y separar claramente información operacional de inteligencia derivada.

Como atributos de calidad se priorizan oportunidad, consistencia, recuperabilidad, escalabilidad y trazabilidad. El sistema operacional confirma disponibilidad, ejecuta reservas, procesa pedidos, pagos, picking y despachos; Lumina no autoriza por sí sola una venta ni se convierte en dependencia obligatoria del camino transaccional.

3.4 Indicadores y método de medición

Para los indicadores de oportunidad se medirá el porcentaje de casos que cumple el tiempo objetivo definido. Como meta inicial, al menos el 95 % de las alertas deberá estar disponible dentro del umbral establecido para la carga evaluada. La medición se realizará por intervalos de carga y por tipo de evento, sin ocultar errores o datos tardíos. Los totales se conciliarán a igual granularidad y las señales conservarán entidad, momento y causa. El beneficio se estimará comparando períodos o grupos equivalentes y registrando la actuación; la detección técnica no equivale automáticamente a una incidencia evitada.

3.5 Supuestos, restricciones, dependencias y exclusiones

Se asumen fuentes accesibles, correspondencias válidas de SKU y ubicación, responsables capaces de actuar y sistemas operacionales que mantienen la autoridad sobre pedidos, inventario, reservas, despacho, pagos y mantenimiento. Para cliente se asume una capacidad externa de MDM o resolución de identidad que proporcione un identificador canónico; Lumina consume esa identidad, pero no la gobierna como registro maestro.

Figura 4: El valor esperado se verifica relacionando una señal con la actuación realizada y su resultado operativo.

Se mantiene la estrategia híbrida con predominio sintético para validación y al menos un dataset público de referencia. Se excluyen del diseño detallado inicial la sustitución del ERP, OMS, WMS, TMS, CRM, MDM, sistemas de mantenimiento, la ejecución de pagos o despachos y un despliegue productivo multirregión. Las metas y retenciones se ajustarán con datos medidos. La propiedad de los datos permanece en RetailSmart.

Capítulo

4

Estrategia de datos y escenarios de negocio

4.1 Inventario y clasificación de fuentes

La operación objetivo integra fuentes propias de aplicaciones de canal, pedidos y ERP; sensores de tienda y almacén; GPS de reparto y telemetría de refrigeración. Cada registro debe conservar fuente, tiempo y entidad. Los datos de interacción explican cambios recientes de demanda; pedidos e inventario sustentan planificación y conciliación; logística y telemetría permiten reconocer desvíos de ejecución o condición.

4.2 Evaluación de datasets públicos de referencia

Tabla 4: Utilidad y límites de los datasets públicos

Dataset	Aplicación de referencia	Límite de interpretación
Olist	Pedidos y contexto logístico; candidato para análisis de entregas y flete	Sus clientes y productos no equivalen a los de otras fuentes.
UCI Online Retail	Transacciones por producto y fecha para patrones de compra	No representa GPS, sensores ni condición de activos.
theLook eCommerce	Estructura de comercio electrónico disponible en BigQuery	Es público y sintético; no es observación real de RetailSmart.

La evaluación identifica dónde aporta cada conjunto; no demuestra representatividad del negocio. El origen sintético de theLook está documentado por Google. UCI describe transacciones de un comercio británico y Olist publica su conjunto en Kaggle [6, 5, 4].

4.3 Estrategia híbrida con predominio sintético

La validación usará escenarios reproducibles para controlar tasas, anomalías y relaciones entre entidades. Un histórico público aportará estructura y una referencia transaccional; Olist es un candidato para el escenario logístico y UCI para ventas. En producción, estos conjuntos se sustituyen por fuentes empresariales. El histórico público y el generador no se presentarán como datos reales de los clientes de RetailSmart.

Figura 5: Históricos de referencia y eventos sintéticos aportan funciones complementarias; la integración conserva el origen y utiliza correspondencias validadas.

4.4 Correspondencia entre fuentes, entidades y verticales

Las entidades principales son producto, ubicación, pedido, envío, activo y tiempo. SKU y ubicación relacionan disponibilidad con demanda; pedido o envío relaciona transacciones con

tracking; activo y ubicación vinculan telemetría con operación. La matriz del anexo A detalla esta correspondencia. Una fuente puede servir a varias verticales sin duplicar su definición ni atribuirle cobertura que no posee.

4.5 Escenarios controlados

Tabla 5: Escenarios de validación y respuesta esperada

Escenario	Condición controlada	Comprobación
Operación normal	Stock y condiciones estables	Flujo conciliado y ausencia de alertas injustificadas.
Alta demanda	Mayor tasa de clics y descenso de stock correlacionado	Señal oportuna y backlog que se recupera.
Anomalía de activo	Temperatura que supera un umbral configurable	Activo, evidencia y responsable de revisión identificados.

4.6 Claves y reglas de correspondencia

Los datasets se conservan independientes. No se unen clientes o productos por coincidencia de identificador, descripción o importe. El generador puede tomar un catálogo seleccionado y registrar un mapa versionado hacia los SKU del escenario. Un registro sin equivalencia sustentada se mantiene separado y se marca como tal. Antes de cruzar varias observaciones con una venta se agrega a una granularidad compatible para evitar multiplicar importes.

La figura 6 sintetiza la independencia de las fuentes y el uso de correspondencias sustentadas.

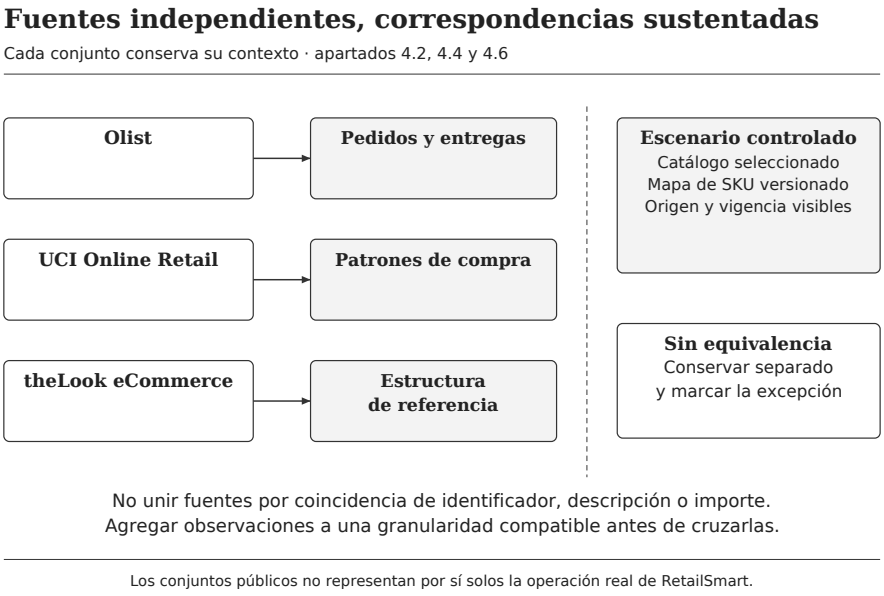

Figura 6: Uso independiente de las fuentes y validación de equivalencias del escenario.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

Capítulo

5

Arquitectura de Solución de extremo a extremo

5.1 Principios y decisiones de diseño

El diseño preserva la autoridad de los sistemas operativos, desacopla publicación y consumo, conserva evidencia de origen y separa calidad de datos de su uso. El cómputo continuo se reserva a decisiones cuya utilidad disminuye con la demora. El procesamiento batch consolida históricos y planes. Las responsabilidades lógicas no obligan a crear un servicio o job independiente por cada caja del diagrama.

La Arquitectura de Solución documenta las decisiones arquitectónicas y su correspondencia con componentes, flujos, contratos y tecnologías. Sus vistas representan el modelo de solución. ArchiMate puede utilizarse como notación de modelado. El catálogo y las especificaciones de contratos se mantienen consistentes con el diseño aprobado y con su versión.

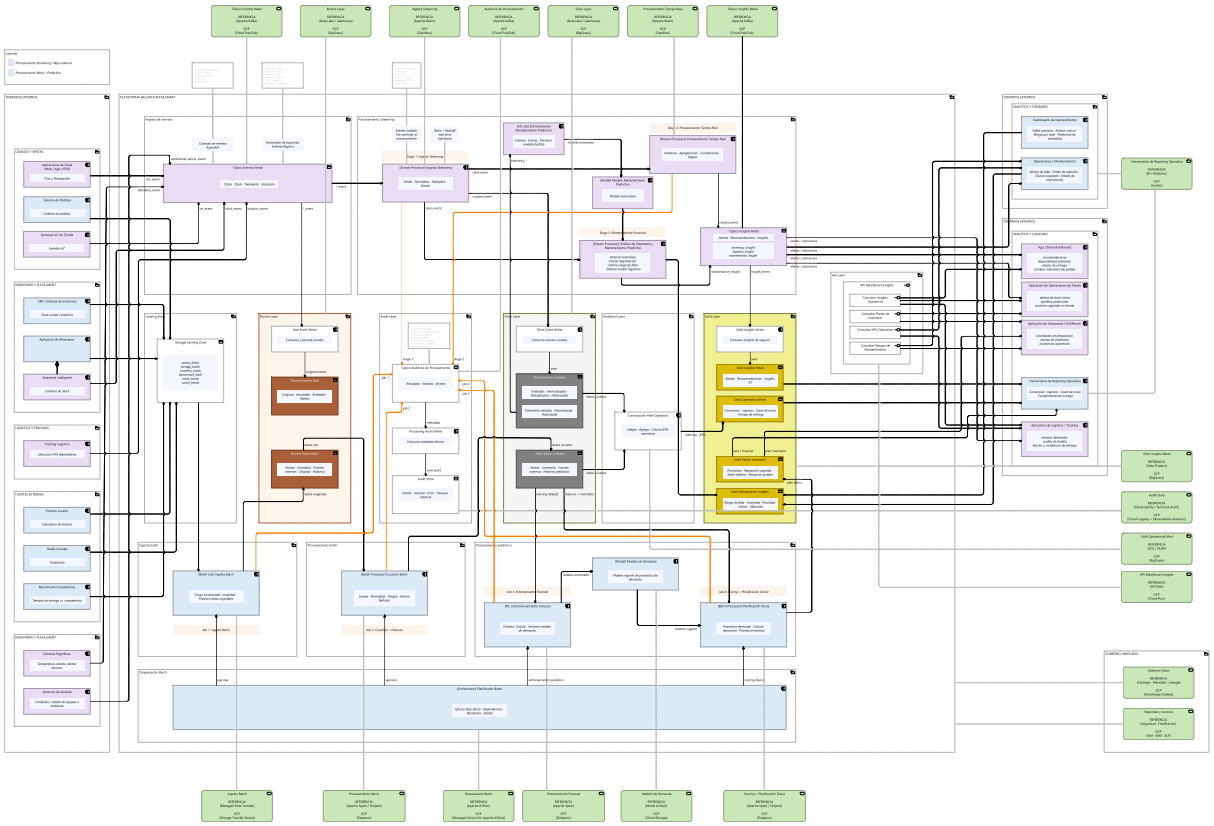

Figura 7: Arquitectura final aprobada de Lumina Retail, exportada desde el modelo ArchiMate canónico.

5.2 Vista de negocio y relación con las verticales

La atención inteligente de pedidos se interpreta como una secuencia de observación, análisis y recomendación sobre una operación que continúa siendo ejecutada por los sistemas transaccionales. V1 aporta conciencia situacional mediante señales recientes; V2 anticipa demanda y necesidades de inventario; V3 explica desempeño y comportamiento transversal; V4 anticipa degradación de activos. Estas capacidades pueden converger sobre un mismo problema sin convertir a Lumina en el ejecutor de la acción.

La figura 8 vincula estas capacidades con el recorrido del pedido.

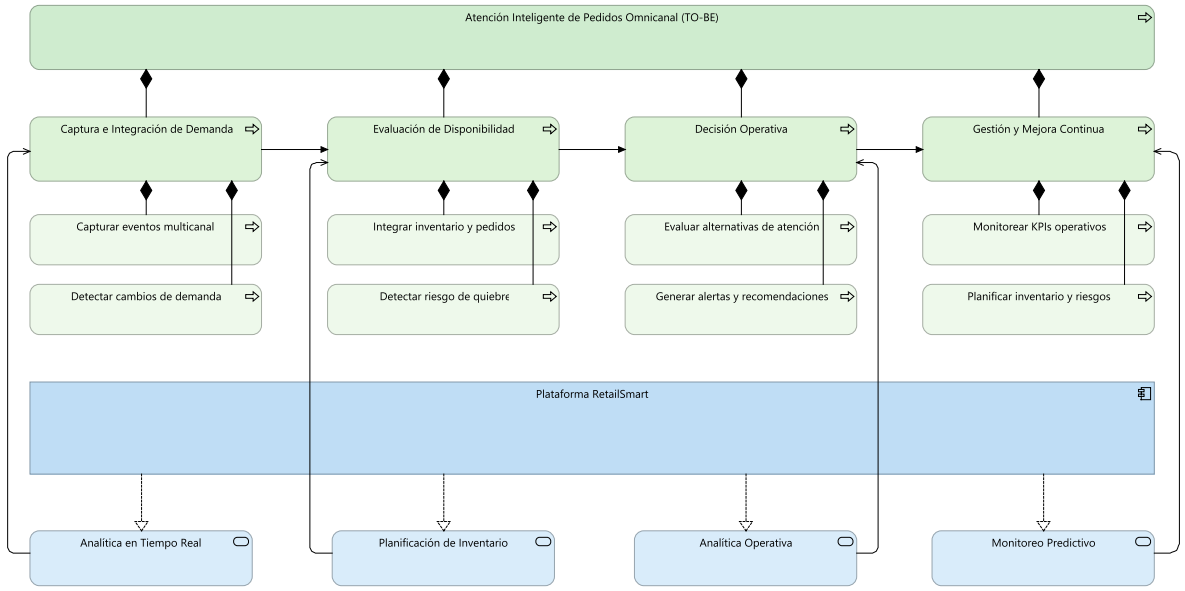

Figura 8: Atención inteligente de pedidos propuesta.
Fuente: Modelo de solución elaborado por el equipo [7].

5.3 Vista de aplicaciones y servicios de datos

Canales, pedidos, ERP, almacenes, logística, CRM, MDM y mantenimiento conservan sus funciones operacionales. La plataforma recibe datos y eventos y entrega señales, planes, indicadores, predicciones y recomendaciones. Los consumidores deben conocer vigencia, calidad y contexto antes de actuar.

Para analítica visual, las vistas autorizadas de BigQuery Gold se plantean para consumo en Data Studio. Data Studio cumple el rol de visualización e informes y no se considera un motor de procesamiento de la plataforma.

Las consultas o APIs posteriores exponen productos de información; una reserva, un pago, una orden de picking, una asignación de vehículo, un cambio de despacho o una intervención de mantenimiento sigue requiriendo validación y ejecución en el sistema transaccional correspondiente. Las vistas completas de aplicaciones frente a procesos se incluyen en el anexo E.

5.4 Vista tecnológica y correspondencia con GCP

Tabla 6: Correspondencia entre componentes de solución y servicios

Componente de solución	Materialización prevista	Responsabilidad
Tópico Eventos Retail	Pub/Sub	Desacoplar productores de consumidores.
Procesamiento Streaming	Apache Beam en Dataflow	Validar, normalizar y evaluar reglas o ventanas.
Bronze Eventos Raw	Cloud Storage	Conservar payload y origen.
Silver Eventos Curados	Cloud Storage y Parquet	Mantener datos integrables y controlados.
Tópico Insights Retail	Pub/Sub	Distribuir señales de negocio.
Gold Insights Retail	BigQuery	Preparar resultados de consulta y exposición.

5.5 Recorrido por ingesta, procesamiento, almacenamiento y exposición

La figura 9 resume el flujo sin sustituir las vistas detalladas de la Arquitectura de Solución. La persistencia raw y la evaluación de señales pueden avanzar en paralelo, coordinadas por identidad y conciliación. No es necesario leer un archivo Bronze para producir cada alerta. La exposición integra resultados mediante consultas y servicios de datos.

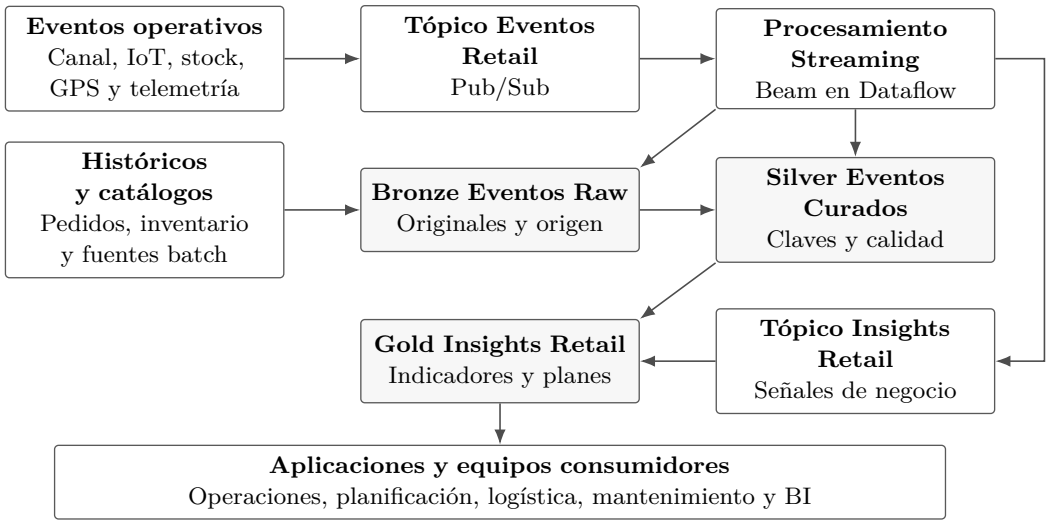

Figura 9: Síntesis vectorial de la arquitectura de datos. Las flechas expresan flujos lógicos de captura, curación, análisis y exposición.

Fuente: síntesis propia alineada con el modelo de solución [7].

5.6 Topología de red y conectividad

La vista presenta la VPC de procesamiento, la subred regional con acceso privado a Google y la ubicación de los servicios respecto de la red.

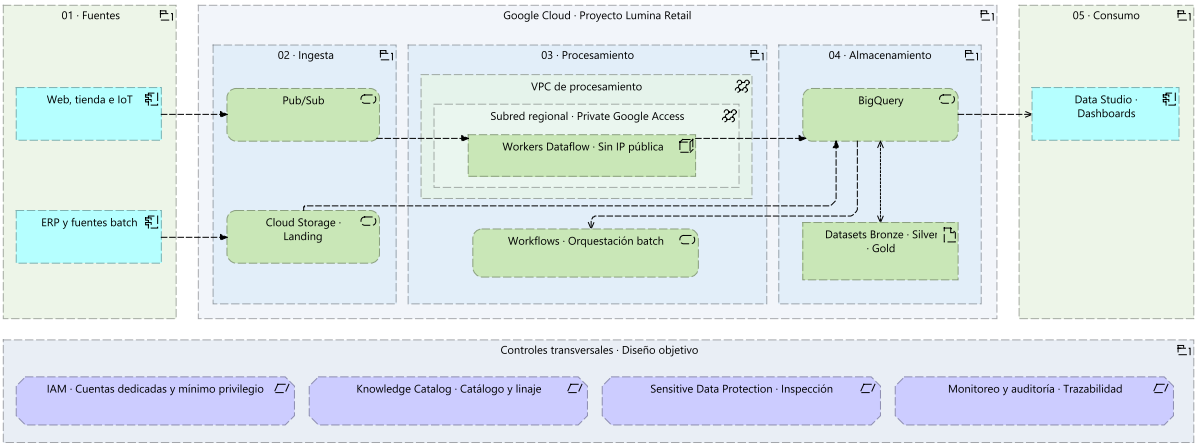

Figura 10: Vista de red de la arquitectura objetivo de Lumina Retail.

5.7 Trazabilidad entre elementos, componentes y requisitos

La trazabilidad sigue la secuencia problema, capacidad, componente, dato y validación. Por ejemplo, baja visibilidad de stock se vincula a disponibilidad por SKU y ubicación, a ingesta de `stock_event`, a curación y a una señal verificable. El catálogo de recursos preserva el identificador lógico y el nombre físico. Las matrices anexas permiten seguir la relación entre fuentes, componentes y resultados.

Capítulo

6

Diseño detallado de ingesta e integración

6.1 Criterios para seleccionar batch o streaming

Streaming se usa cuando la demora cambia la decisión, como riesgo de quiebre o condición de un activo. Batch se usa para consolidación, reconciliación y planes diarios. La selección considera frecuencia del origen, granularidad y tiempo útil del resultado. Se evita exigir baja latencia a una fuente que solo dispone de una actualización diaria.

6.2 Flujo streaming y contratos de eventos

Los productores publicarán los seis tipos definidos por la arquitectura en el Tópico Eventos Retail. La validación y normalización producirán datos curados y las reglas generarán señales hacia el Tópico Insights Retail y Gold. Un contrato debe identificar entidad, origen, versión y tiempo. El perfil semántico del anexo es ilustrativo; no modifica los contratos vigentes del repositorio.

Tabla 7: Eventos de entrada y uso principal

Evento	Fuente	Uso principal
`clic_event`	Canal digital	Cambios de interés e interacción.
`iot_event`	Sensores de tienda	Condiciones de operación.
`stock_event`	Inventario instrumentado	Disponibilidad por SKU y ubicación.
`location_event`	GPS	Posición y avance del envío.
`telemetry_event`	Refrigeración	Condición de activos.
`warehouse_sensor_event`	Almacén	Condiciones y riesgo operativo.

6.3 Flujo batch y fuentes históricas

Las cargas de pedidos, inventario y catálogo conservarán un identificador de lote, fuente, fecha y totales. Bronze recibe el archivo o extracción original; la transformación valida y consolida Silver; las agregaciones y estructuras analíticas preparan Gold. La disponibilidad del plan diario se coordinará con la ventana de llegada del origen. Una carga incompleta no se publica como período cerrado.

6.4 Validación, metadatos y versionamiento de esquemas

Se comprueban campos obligatorios, tipos, rangos, unidades y claves de referencia. El payload original y el motivo de incumplimiento permiten investigar. La compatibilidad de un nuevo esquema se revisa antes de cambiar productores o consumidores. Se registran tiempo de ocurrencia y tiempo de ingesta para medir oportunidad sin confundir retraso del origen con demora del pipeline.

El tiempo de ocurrencia y el de ingesta permiten distinguir vigencia del dato y demora del pipeline.

6.5 Duplicados, eventos tardíos, errores y reprocesamiento

El identificador estable del evento y las escrituras idempotentes evitan efectos equivalentes repetidos. Se evaluarán ventanas de 30 segundos y una tolerancia inicial de dos minutos; las cifras permanecen configurables. La secuencia de origen o la vigencia impiden que un stock atrasado sustituya un estado más reciente. Dataflow no garantiza una única llamada externa aunque controle resultados dentro del procesamiento [3]. Los inválidos se separan en una ruta controlada, sin añadir tipos de evento.

La figura 11 resume las responsabilidades lógicas y el tratamiento de excepciones.

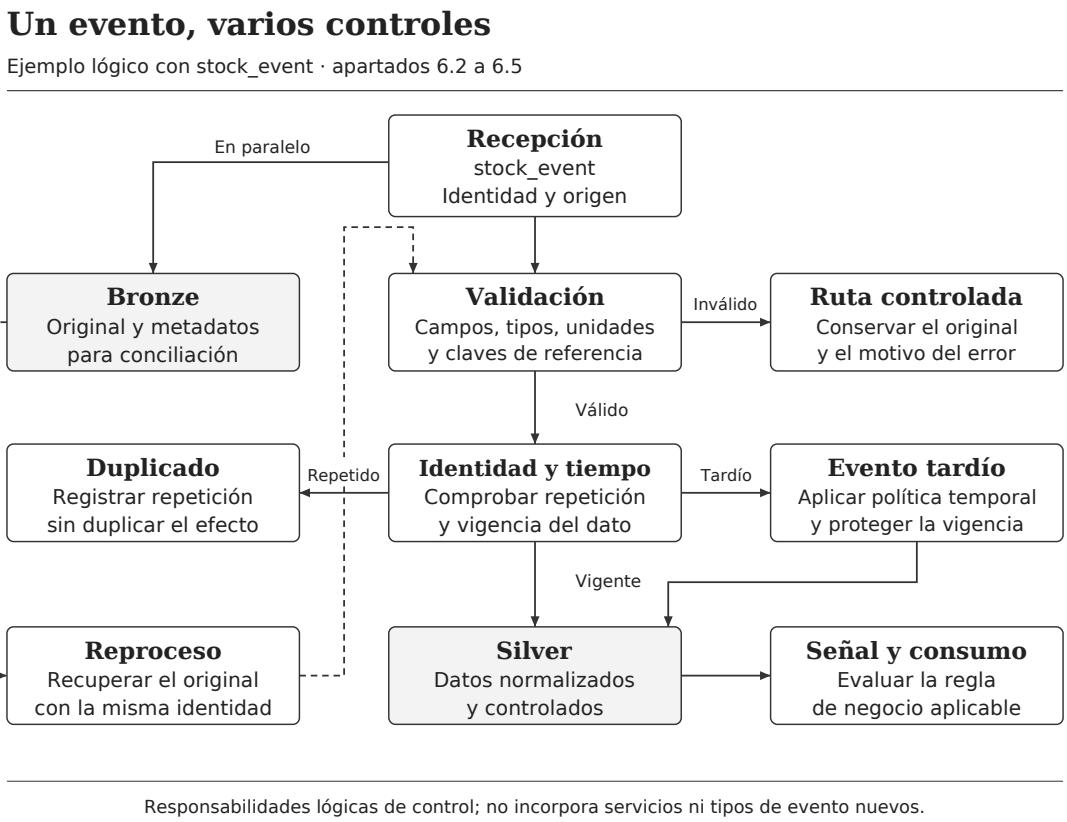

Figura 11: Recorrido lógico de un evento: preservación, validación, identidad, vigencia y reproceso.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

6.6 Frecuencias, latencias y volúmenes estimados

Se propone una prueba nominal de 20 eventos/s de 1.5 KiB y un pico de 400 eventos/s durante dos horas al día por tres días. La meta inicial es que al menos el 95 % de las alertas esté disponible en no más de un minuto bajo carga nominal, y que el plan diario esté disponible antes de las 07:00 de Lima. El intervalo de archivo, el tamaño de lote y la frecuencia de extracción se ajustarán con mediciones; el número de clientes no determina por sí solo la tasa de eventos.

Capítulo

7

Diseño de almacenamiento y organización de datos

7.1 Justificación de los motores de almacenamiento

La propuesta combina un Data Lake de archivos con un Data Warehouse analítico. Cloud Storage conserva originales y Parquet curado; BigQuery organiza consultas y productos de consumo. Esta separación permite reprocesar sin reconstruir el origen y optimizar consultas sin trasladar toda la operación a un motor transaccional. Las capas Medallion por sí solas no constituyen un lakehouse transaccional.

7.2 Responsabilidad de Bronze, Silver y Gold

Tabla 8: Responsabilidades de las capas de datos

Capa	Contenido	Condición de publicación
Bronze	Payloads y archivos originales con origen	Recepción identificada y evidencia recuperable.
Silver	Datos normalizados con claves y unidades consistentes	Reglas de calidad y correspondencia conocidas.
Gold	Señales, planes e indicadores por granularidad de negocio	Definición del indicador, vigencia y permisos de consumo.

Bronze Conservar | **Silver** Preparar | **Gold** Servir información

Figura 12: Tres responsabilidades de la plataforma: preservar los originales, preparar datos consistentes y producir información útil para el negocio.

7.3 Formatos, particionamiento y organización física

Bronze conserva JSON y formatos originales. Silver usa Parquet para lectura selectiva y compresión; se organiza por fuente, tipo y fecha del evento. Gold particiona por fecha del negocio y agrupa por claves utilizadas en consultas. Se propone compactar archivos para evitar objetos pequeños y separar temporales técnicos. Región de cómputo y ubicaciones de datos deben ser compatibles.

7.4 Retención y ciclo de vida

Se proponen 30 días en Bronze, 90 días en Silver y 12 meses de resultados Gold para el piloto. Las retenciones deberán validarse según auditoría y recuperación. Bronze será de escritura añadida a nivel lógico; la inmutabilidad exige permisos y política de conservación. La retención no debe

impedir el cumplimiento de las políticas de eliminación y privacidad. El archivo histórico de largo plazo se decidirá con una necesidad explícita.

7.5 Modelo conceptual y estructuras para consumo

Las entidades son producto, ubicación, pedido, envío, activo y fecha. Los hechos de pedido y entrega se relacionan con dimensiones compartidas; señales y telemetría conservan su propia granularidad. Los productos Gold comprenden disponibilidad y alertas por entidad, plan diario de inventario, indicadores operativos y condición de activos. Cada producto registra fecha de actualización y cobertura de datos. La figura 13 representa las relaciones conceptuales y conserva la granularidad definida.

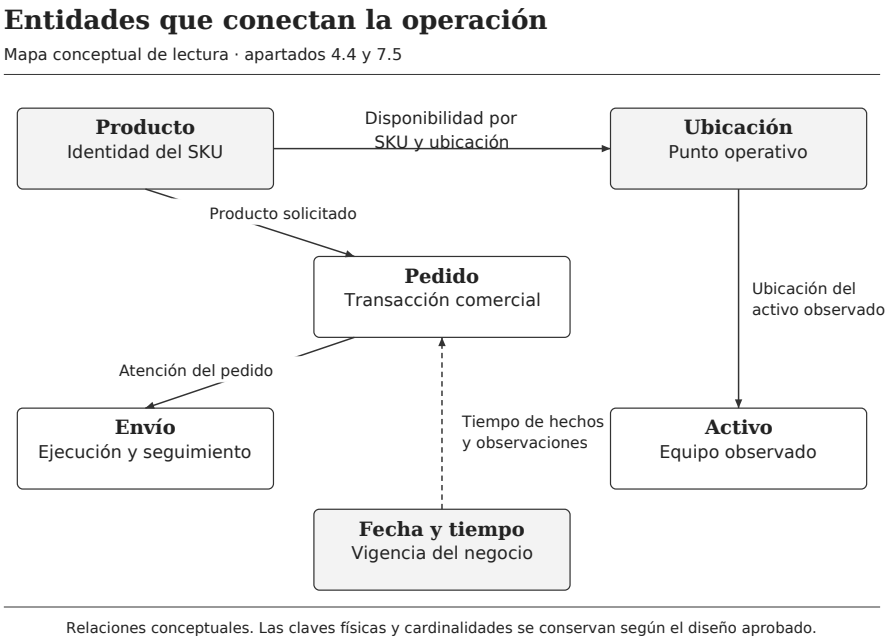

Figura 13: Entidades de negocio y relaciones conceptuales descritas en el diseño aprobado.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

7.6 Integración del histórico con eventos operativos

Los eventos enriquecen la visión reciente y el histórico permite contexto y conciliación. La unión se realiza sobre claves válidas y una referencia temporal compatible. Antes de cruzar varios eventos con una transacción se agrega al nivel de la venta. La conversión exige una relación sustentada entre interacción y compra; en ausencia de esa relación se muestran ambas métricas por separado.

Capítulo

8

Selección y justificación tecnológica

8.1 Criterios y alternativas consideradas

La comparación considera oportunidad de la decisión, esfuerzo de operación, portabilidad, seguridad y mantenibilidad. Se evalúa una base gestionada en GCP frente a una plataforma autogestionada con componentes abiertos. La primera reduce tareas de operación, mientras la segunda ofrece mayor control a cambio de desplegar, actualizar, dimensionar y recuperar más infraestructura. Ninguna alternativa elimina la necesidad de gobierno o soporte.

Tabla 9: Alternativas tecnológicas y compromisos

Decisión	Opción del diseño	Alternativa y compromiso
Mensajería	Pub/Sub; desacoplamiento sin administrar brokers	Kafka; mayor control y portabilidad del protocolo, con operación propia o capacidad gestionada.
Streaming	Apache Beam en Dataflow	Otro runner o Flink; revisar conectores, estado y semántica de recuperación.
Archivos	Cloud Storage con formatos abiertos	Almacenamiento compatible con objetos; revisar garantías y operación.
Analítica	BigQuery para Gold y consultas SQL	Motor abierto como Trino; requiere organizar capacidad y operación.

8.2 Sustento de los componentes seleccionados

La selección busca reducir la operación de infraestructura sin perder interoperabilidad donde aportan valor los estándares abiertos. Cada alternativa implica compromisos de control, portabilidad y mantenimiento.

Tabla 10: Justificación técnica de los servicios seleccionados

Servicio	Motivo de selección	Alternativa y compromiso
Pub/Sub	Desacopla productores y consumidores sin administrar brokers.	Kafka brinda mayor control y portabilidad; requiere operar capacidad, disponibilidad y actualizaciones.
Apache Beam en Dataflow	Beam expresa transformaciones portables y Dataflow administra su ejecución y escalado.	Flink u otro runner ofrece más control; en modalidad autogestionada requiere operar el clúster.
Cloud Storage y Parquet	El servicio administrado conserva archivos; Parquet facilita lectura columnar y portabilidad.	MinIO u otro almacenamiento autogestionado ofrece control, con responsabilidad adicional de disponibilidad y mantenimiento.
BigQuery	Permite consultas SQL analíticas sin administrar clústeres.	Trino es una alternativa abierta, pero requiere dimensionar y operar cómputo.
Workflows y Cloud Run	Workflows coordina servicios de GCP y Cloud Run aloja la API sin mantener servidores.	Airflow o Kubernetes ofrecen más control y flexibilidad; aumentan la operación de la plataforma.
Knowledge Catalog y Sensitive Data Protection	Integran catálogo, linaje e inspección de datos sensibles con los servicios de GCP.	OpenMetadata, Apache Atlas y detectores abiertos requieren despliegue e integración de componentes adicionales.
Data Studio	Se propone para visualizar vistas autorizadas de BigQuery Gold.	Superset permite autogestión, pero requiere alojar y mantener la plataforma de BI. Data Studio es un consumidor propuesto, no un servicio desplegado en esta implementación.

La elección distribuye responsabilidades por capa y evita utilizar el almacén analítico para coordinar transacciones. Los formatos abiertos, la lógica separada de conectores y los contratos versionados reducen costos de salida, pero no hacen automática una migración entre plataformas [1, 2].

8.3 Tecnologías abiertas y servicios administrados de GCP

RetailSmart ha expresado una preferencia por tecnologías abiertas. Python, Beam, Parquet y lógica SQL portable atienden parte de ese objetivo. Pub/Sub, Dataflow, Cloud Storage y BigQuery son servicios propietarios; usar clientes abiertos no los convierte en software abierto. Por ello, la arquitectura gestionada requiere una decisión explícita sobre la dependencia de plataforma. Si la prioridad es evitar dependencia de proveedor, se deberá comparar una alternativa abierta antes de consolidar la implementación.

8.4 Compromisos de portabilidad, rendimiento y operación

Se acepta dependencia de servicio a cambio de reducir operación inicial. La salida se facilita con formatos abiertos, metadatos exportables, lógica separada de conectores y contratos versionados, sin prometer migración automática. Se revisará el enfoque si las restricciones de residencia o la política de software superan el beneficio de la gestión delegada. Los modelos predictivos se incorporan solo si superan un baseline simple y justifican su mantenimiento.

8.5 Registro de decisiones de arquitectura

Tabla 11: Decisiones y condiciones de aceptación

ID	Decisión de diseño	Consecuencia o condición
ADR 01	Integración híbrida y escenarios sintéticos controlados	Se complementa con un histórico público; el impacto real exige piloto operativo.
ADR 02	Bronze y Silver en objetos; Gold analítico	Separar evidencia de preparación y consumo.
ADR 03	Identidad estable e idempotencia	Reproceso sin duplicar efectos de negocio.
ADR 04	Despliegue regional inicial	La recuperación ante pérdida de región requiere una copia externa y un procedimiento probado.
ADR 05	Uso de servicios GCP gestionados	Excepción pendiente frente al mandato de código abierto.

La figura 14 muestra la secuencia para actualizar el diseño y su documentación antes de modificar la implementación.

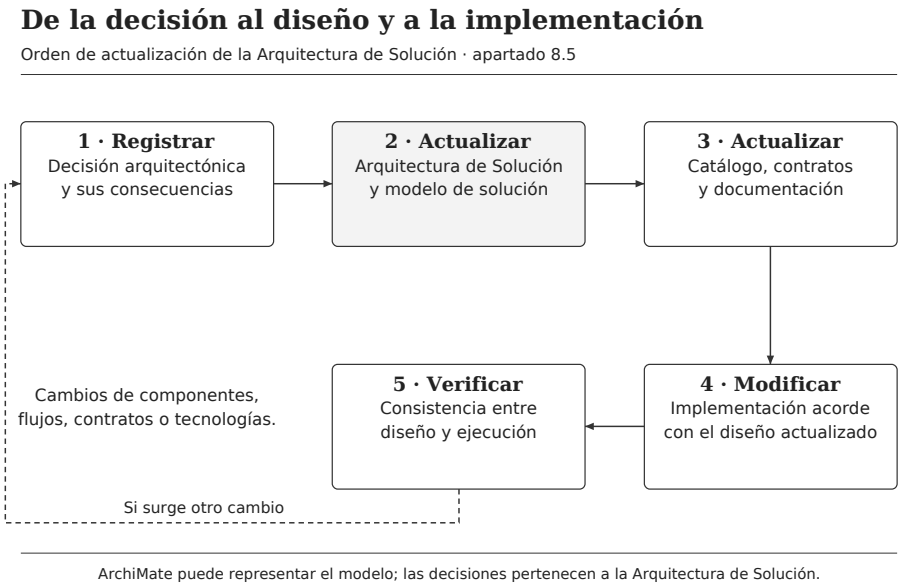

Figura 14: Secuencia de actualización del diseño antes de modificar la implementación.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

Capítulo

9
Escalabilidad y rendimiento

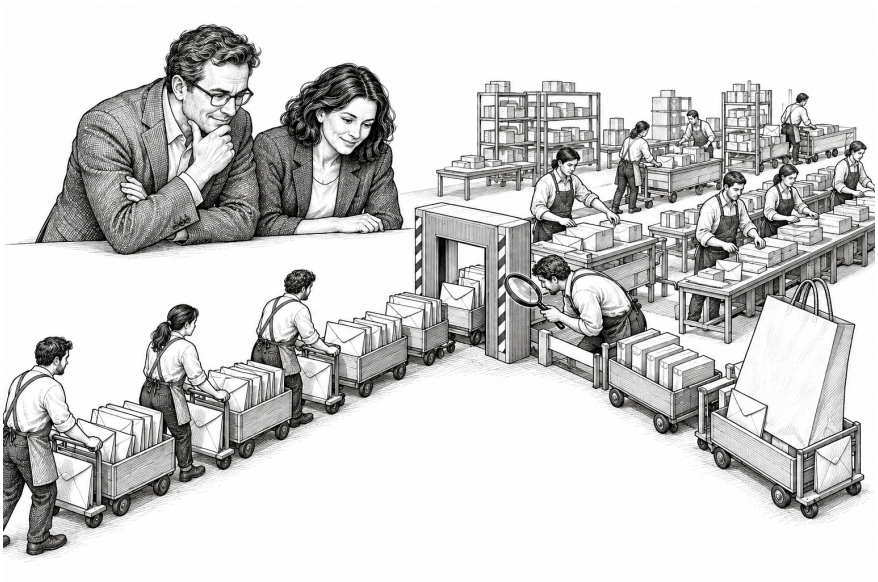

9.1 Volumetría y carga normal

El escenario de referencia utiliza 20 eventos/s de 1.5 KiB durante 30 días. Esto equivale a 51,84 millones de eventos y aproximadamente 74,2 GiB de payload raw mensual. Son parámetros de un piloto acotado, no una extrapolación desde nueve millones de clientes. El número de workers es una hipótesis de capacidad que debe validarse.

9.2 Black Friday y Cyber Monday

Se propone aumentar a 400 eventos/s durante dos horas al día por tres días, manteniendo igual tamaño medio. El mes resultante contiene aproximadamente 60,05 millones de eventos. La prueba observa aumento de demanda, descenso correlacionado de stock y acumulación logística. Además de la latencia durante el pico, se mide cuánto tarda en vaciarse el trabajo pendiente una vez que la tasa retorna a normalidad.

9.3 Capacidad y escalamiento por capa

Tabla 12: Controles de capacidad por capa

Capa	Señal a observar	Acción a evaluar
Productores y captura	Errores de publicación, cuota y reintentos	Regular tasa y tamaño de lote; evitar pérdida silenciosa.
Streaming	Backlog, tiempo de respuesta de alertas, CPU y claves calientes	Revisar paralelismo, ventanas y límites de workers.
Archivos	Archivos pequeños y demora de escritura	Ajustar tamaño y frecuencia de consolidación.
Gold y consultas	Demora y bytes escaneados	Particionar, seleccionar columnas y preparar agregados.

9.4 Cuellos de botella y saturación

Un backlog creciente puede originarse en claves concentradas, un destino lento, cuotas o lógica de procesamiento intensiva. Añadir workers no resuelve necesariamente el límite del destino. Se revisará el tramo que acumula trabajo antes de incrementar capacidad. La retención protege una ventana de recuperación, pero no representa almacenamiento ilimitado. Batch y consultas masivas se programarán para no competir innecesariamente con decisiones urgentes.

9.5 Objetivos y pruebas de rendimiento

La meta nominal es que al menos el 95 % de las alertas esté disponible en ≤ 60 s, acompañada de conciliación y registro de errores. Para el pico se verificará crecimiento y recuperación del backlog sin pérdida no explicada; el umbral de latencia de campaña se acordará con la necesidad operativa. El escenario de prueba contempla dos workers de 2 vCPU y 8 GiB y hasta ocho durante seis horas de pico. Esta capacidad debe confirmarse experimentalmente. La figura 15 sintetiza los escenarios de carga propuestos y sus condiciones de validación.

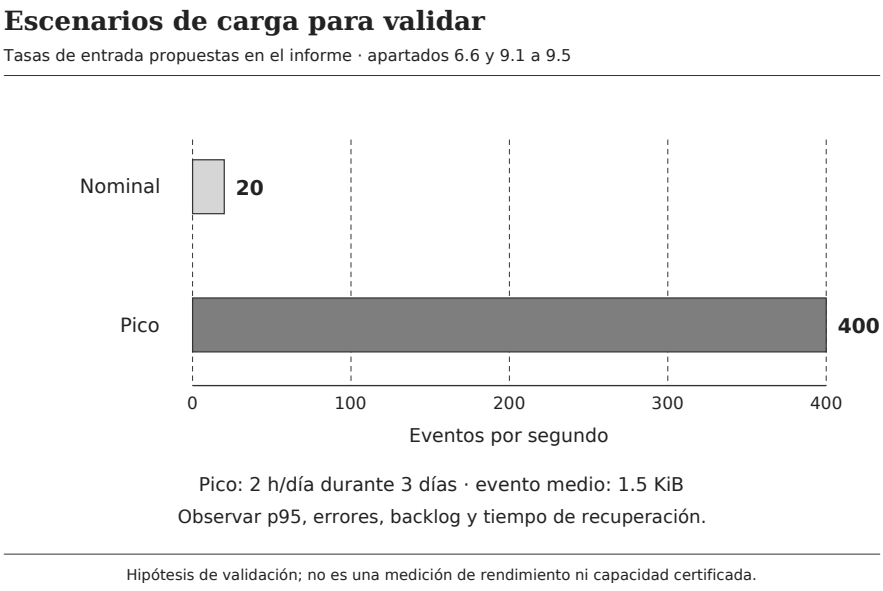

Figura 15: Escenarios nominal y pico propuestos para validar el comportamiento del flujo.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

Capítulo

10

Justificación económica y estimación de costos

La estimación económica se consolida en el visor web de costeo de Lumina Retail. El visor relaciona cada servicio de la arquitectura con su capacidad, unidad de cobro, costo base y escenarios de crecimiento. Este capítulo presenta únicamente el resumen ejecutivo; el desglose por servicio, los supuestos y la trazabilidad de cada tarifa se mantienen en el entregable web y su exportación de datos.

Tabla 13: Escenarios de costo de infraestructura GCP

Escenario	Mensual	Anual	Uso
Base actual	**USD 3,271.71**	**USD 39,260.52**	Operación nominal
Conservador (1,8×)	**USD 5,889.08**	**USD 70,668.96**	Crecimiento y variación operativa
Máxima demanda (2,5×)	**USD 8,179.28**	**USD 98,151.36**	Picos, mayor consumo y holgura

El costo mensual base es el indicador principal de control presupuestario. La proyección conservadora aplica un factor de 1,8× y la máxima demanda un factor de 2,5× sobre el consumo base. Estos factores permiten presupuestar antes de disponer de telemetría productiva y deben recalibrarse con la facturación observada.

Tabla 14: Supuestos de dimensionamiento utilizados en el visor

Variable	Escenario de planificación
Región	us-central1
Disponibilidad	24/7
Clientes activos	9 millones
Sucursales	8
Carga nominal	20 eventos/s
Pico de campaña	400 eventos/s
Dataflow	2 workers base; hasta 8 en pico; 4 vCPU y 15 GiB por worker
BigQuery	2 TiB consultados/mes
Modelo de precios	USD, on-demand; sin créditos ni descuentos

Los servicios considerados corresponden a los componentes de la arquitectura: Pub/Sub, Dataflow, Cloud Storage, BigQuery, Cloud Logging, Cloud Monitoring, Persistent Disk, Storage Transfer Service, Workflows, Dataproc, Cloud Run, Artifact Registry, Dataplex/Knowledge Catalog, KMS/IAM/DLP y Looker. Los precios unitarios se contrastan con las tarifas oficiales de Google Cloud; cuando el consumo aún no tiene telemetría, el visor utiliza un supuesto técnico explícito y lo identifica como tal.

El resultado constituye un presupuesto de planificación tecnológica, no una factura ni un compromiso comercial. Las tarifas efectivas pueden variar por región, modalidad de contratación, descuentos por compromiso, transferencia, retención y consumo real. La aplicación web es la fuente operativa para recalibrar el costeo; el informe se actualizará con la versión aprobada del escenario.

Capítulo

11
Fiabilidad, alta disponibilidad y recuperación

11.1 Escenarios de falla y consecuencias operativas

La solución debe reconocer fuentes caídas, fallas de procesamiento, datos inválidos y pérdida regional. El riesgo principal es que una información incompleta o vencida se consuma como disponibilidad vigente. La respuesta combina marcar degradación, conservar evidencia, controlar salidas y recuperar procesamiento. Alta disponibilidad local y recuperación ante desastre regional son responsabilidades relacionadas, pero distintas.

Como criterio de alta disponibilidad, se evita introducir coordinadores autogestionados de instancia única. Se debe comprobar la cobertura zonal de los servicios elegidos y ensayar el reinicio de workers sin pérdida no explicada. La continuidad ante pérdida completa de región requiere un diseño adicional de recuperación.

11.2 Indisponibilidad del inventario de una tienda

Se mantiene la última lectura como referencia y se marca su vigencia. Operaciones debe saber que la fuente está degradada antes de confirmar un compromiso. La venta se valida en el sistema transaccional o mediante una alternativa operativa autorizada. Un heartbeat o una regla de frescura permite proponer detección de indisponibilidad en cinco minutos o menos, pendiente de prueba. La figura 17 presenta una maqueta conceptual para comunicar la vigencia de la fuente

Figura 16: Ante una fuente de inventario indisponible, la vigencia del dato y la verificación operativa condicionan la confirmación del pedido.

sin representar una aplicación implementada.

11.3 Tolerancia a fallos y recuperación del procesamiento

Los mensajes retenidos, los originales y los puntos persistidos permiten retomar el flujo. Se recupera configuración y permisos y se reprocesa con la misma identidad lógica. La conciliación debe comparar entradas, duplicados, rechazados y resultados. Los consumidores de señales también deben controlar repetición; la garantía interna del runner no basta para una acción externa exactamente una vez [3].

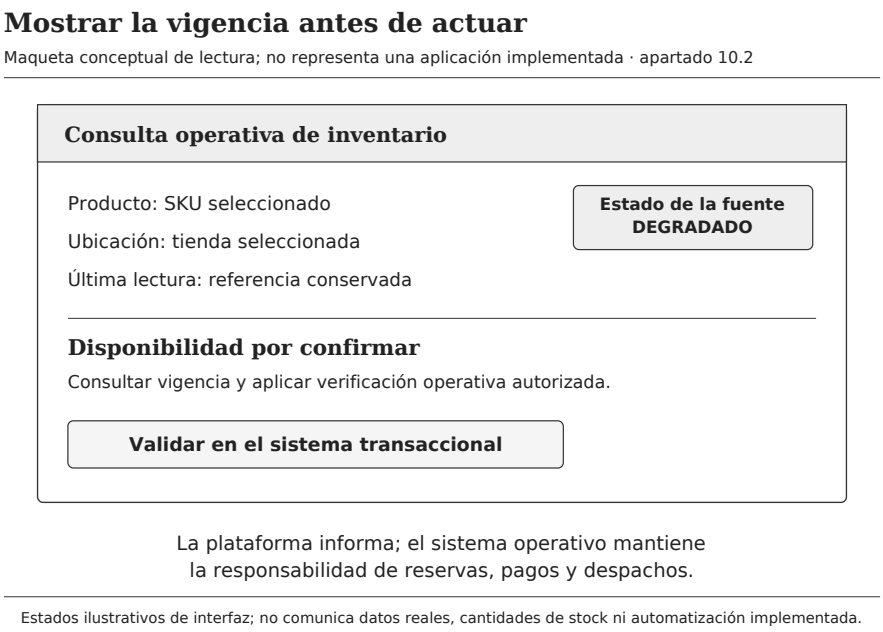

Figura 17: Maqueta conceptual para comunicar vigencia y degradación; no representa una aplicación implementada.

Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

11.4 Objetivos RTO y RPO propuestos

Tabla 15: Objetivos iniciales de recuperación

Incidente	Objetivo propuesto	Condición y evidencia
Fuente de inventario caída	Detección ≤ 5 min	Regla de frescura y visibilidad de estado degradado.
Job o worker indisponible	RTO ≤ 30 min	Recuperar desde datos ya persistidos y retenidos.
Pérdida de región	RTO 4 h y RPO 24 h	Solo tras habilitar y probar una copia fuera de la región.

RTO es el tiempo objetivo de recuperación y RPO la pérdida máxima tolerada. Los valores son decisiones propuestas; no son SLA de GCP ni resultados medidos. El despliegue regional inicial no demuestra por sí solo continuidad multirregión. La figura 18 sintetiza los objetivos propuestos y las condiciones necesarias para validarlos.

11.5 DRP y procedimiento de validación

El procedimiento identifica el incidente, contiene resultados incorrectos, restaura configuración y acceso, recupera datos y concilia antes de reabrir consumo. El simulacro registra tiempos y diferencias y permite ajustar objetivos. La copia externa a la región deberá habilitarse y probarse según la criticidad del servicio.

Figura 18: Objetivos RTO y RPO, condicionados a una copia externa habilitada y probada.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

Capítulo

12

Gobierno, calidad y seguridad de datos

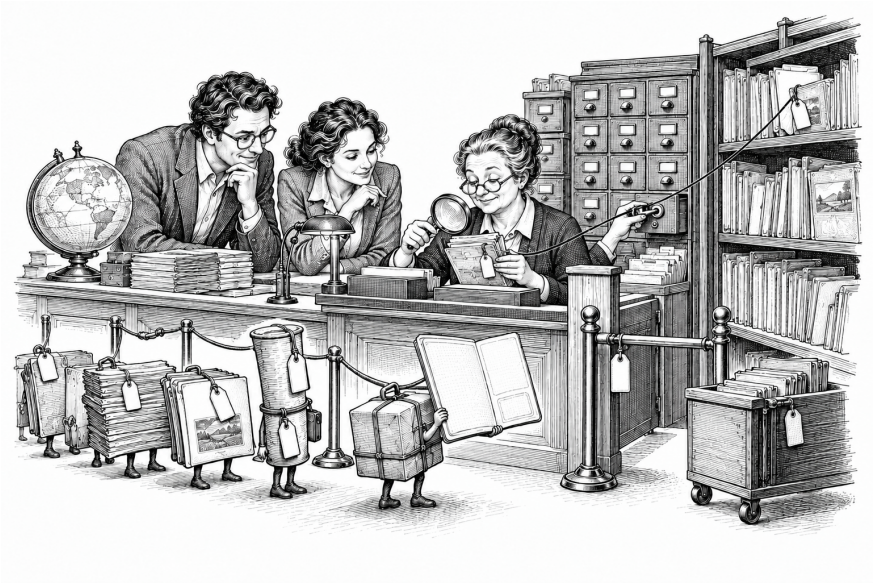

12.1 Responsables y clasificación

RetailSmart conserva la propiedad del dato. Cada dominio debe designar un responsable de definición y calidad y cada producto de información un responsable de consumo. Se propone clasificar los conjuntos según sensibilidad y necesidad operativa, minimizando datos personales. El contrato con el proveedor debe proteger acceso, exportación y continuidad, y dejar clara la titularidad de los datos y de la tecnología.

12.2 Catálogo, diccionario y metadatos

La implementación habilita Knowledge Catalog y Data Lineage, registra metadatos descriptivos en activos BigQuery de las capas Bronze, Silver y Gold, y verifica relaciones de linaje entre productos Gold y vistas de consumo. El catálogo permite mantener contexto de negocio junto con la estructura técnica del activo. El diccionario complementa estos metadatos con el significado de campos, unidades y claves; los metadatos de recepción no sustituyen el tiempo del negocio. La cobertura documentada corresponde a los activos y relaciones revisados en la implementación.

12.3 Linaje desde la fuente hasta el consumo

Un indicador o una señal debe poder rastrearse hasta su evento o lote, la transformación aplicada y la versión de regla o modelo. Se conserva la correspondencia entre fuente y entidad del escenario. El linaje lógico se diseña desde el inicio y la evidencia automática se incorpora con los pipelines. Una flecha en el diagrama expresa una relación prevista, no prueba que el linaje técnico ya esté implementado.

Figura 19: Cada producto de información debe conservar trazabilidad de su origen, sus transformaciones y sus controles de acceso.

12.4 Reglas de calidad e incumplimientos

Las reglas cubren completitud, tipo, rango, unidad, unicidad, frescura y referencia válida. Se concilian entradas con válidos, duplicados y rechazados usando categorías excluyentes definidas para cada conteo. Un incumplimiento conserva causa y origen y puede impedir publicar un período o activar una señal. Los umbrales se acuerdan con el uso del dato y se revisan con los usuarios.

12.5 Identidades, permisos y mínimo privilegio

La arquitectura separa identidades humanas de aprovisionamiento, cuentas de ejecución de cargas y agentes de servicio administrados por Google. Las cuentas de ejecución no requieren claves descargables: los servicios de GCP las asocian al recurso que ejecutan y obtienen credenciales de corta duración. La tabla resume la configuración de la implementación y los ajustes recomendados para los procesos que aún comparten la cuenta predeterminada de Compute Engine.

Tabla 16: Identidades de ejecución y alcance de permisos IAM

Proceso	Identidad configurada	Permisos y alcance	Criterio de gobierno
Dataflow	Cuenta dedicada `$PREFIX-worker`	Dataflow Worker en el proyecto y acceso de objetos en los buckets de artefactos y Silver.	Conservar el acceso limitado a los buckets requeridos; no asignar Editor.
API en Cloud Run	Cuenta dedicada `$PREFIX-api`	BigQuery Job User en el proyecto, lectura de tablas Gold autorizadas y acceso al secreto requerido.	Mantener la lectura a nivel de tabla y el secreto asociado a esta identidad.
Workflows batch	Cuenta predeterminada de Compute Engine	BigQuery Job User en el proyecto; lectura de Bronze y edición de Silver y Gold a nivel de dataset.	Recomendación: asignar una cuenta dedicada al Workflow y limitar sus permisos a las operaciones de orquestación y datasets que necesita.
Actualización programada del Operational Mart	Cuenta predeterminada de Compute Engine, compartida con Workflows	BigQuery Job User en el proyecto y acceso a Silver y Gold para ejecutar la consulta programada.	Recomendación: usar una cuenta dedicada al proceso programado, separada de Workflows y con acceso solo a los datasets requeridos.
Construcción de la API	Cuenta predeterminada de Compute Engine del proyecto	Cloud Run Builder en el proyecto y Artifact Registry Writer en el repositorio de despliegue.	Es una identidad de construcción, distinta de la identidad de runtime de Cloud Run.
Dataproc (opcional)	Cuenta dedicada `$PREFIX-spark`	Dataproc Worker y acceso a los buckets configurados para el proceso.	Aplicar solo si se habilita este componente opcional.

En Workflows y en la actualización programada, la implementación actual reutiliza la cuenta predeterminada de Compute Engine. La separación propuesta por proceso reduce el impacto de una credencial comprometida y permite revisar o revocar permisos sin afectar a otras cargas. BigQuery Job User habilita la creación de trabajos en el proyecto; los permisos sobre datos se limitan por dataset o tabla. La cuenta humana que despliega puede recibir `Service Account User` únicamente sobre la cuenta de ejecución correspondiente, sin convertirla en identidad de runtime.

Los agentes de servicio de Pub/Sub, Dataflow, Knowledge Catalog y otros servicios administrados cumplen funciones propias del plano de control y no reemplazan las cuentas de ejecución de las cargas. Sus permisos deben limitarse al recurso que requiere la integración. La revisión IAM debe confirmar tanto los accesos permitidos como los denegados, evitar roles amplios como Editor y mantener trazabilidad de cambios y asignaciones.

12.6 Cifrado y protección de datos sensibles

La implementación habilita Sensitive Data Protection y mantiene una plantilla regional de inspección con detectores para correo electrónico, teléfono y tarjeta; la configuración evita incluir fragmentos del contenido en los resultados. Esta plantilla se ha verificado mediante una solicitud de inspección de contenido, pero todavía no se ejecutan trabajos de inspección sobre tablas o datasets almacenados en BigQuery. Como siguiente medida de gobierno, se recomienda seleccionar los conjuntos que requieren revisión, ejecutar inspecciones periódicas y registrar en Knowledge Catalog la clasificación aprobada para tablas y columnas. A partir de los hallazgos y la finalidad de uso, se definirán las transformaciones de enmascaramiento o tokenización necesarias antes de publicar los datos en Gold. La inspección identifica posibles datos sensibles; la política de acceso y las transformaciones siguen siendo controles separados.

12.7 Auditoría y trazabilidad

Los logs deben identificar proceso, ejecución, causa de error y entidad técnica sin volcar payload sensible. Las métricas cubren frescura, errores, backlog y oportunidad. La cobertura de auditoría de acceso a datos debe verificarse y habilitarse; la existencia de logs operativos no demuestra auditoría completa. Los cambios relevantes de esquema, permisos y reglas quedan versionados.

12.8 Nomenclatura y catálogo de recursos

Se separa el identificador lógico del nombre físico. El catálogo precede al despliegue y mantiene componente, servicio, entorno, alcance, ubicación, propósito, capa y estado. Los labels facilitan identificar responsables y recursos. Bronze, Silver y Gold pertenecen al atributo de capa; ingesta o seguridad pertenecen al rol. Pub/Sub tiene alcance global y la residencia del mensaje se configura aparte. El anexo C muestra un inventario lógico de referencia.

Capítulo

13

Plan de implementación y validación

13.1 Fase 1: habilitar el flujo prioritario

Seleccionar una combinación acotada de pedidos e inventario, confirmar responsables de datos y acordar las claves maestras. Habilitar la captura, persistencia de originales y validaciones iniciales. El resultado esperado es una vista vigente de disponibilidad por SKU y ubicación, con estado de calidad visible.

13.2 Fase 2: integrar históricos y productos de información

Incorporar cargas históricas, normalizar entidades y publicar productos Gold para planificación e indicadores operativos. Conciliar los resultados con las fuentes autorizadas y documentar excepciones. Los escenarios sintéticos y los conjuntos públicos sirven para validar el comportamiento, no para representar resultados reales de RetailSmart.

13.3 Fase 3: activar consumo operacional

Exponer señales y productos a los equipos de operaciones, planificación y logística mediante consultas, paneles o APIs. Probar el recorrido desde la fuente hasta una decisión registrada. Mantener las acciones transaccionales —reservas, pagos y despachos— en los sistemas operativos.

La actuación de un responsable operativo convierte una señal vigente en una decisión que puede evaluarse.

13.4 Dependencias y criterios de avance

Tabla 17: Condiciones de avance por fase

Fase	Resultado esperado	Condición para avanzar
Flujo prioritario	Disponibilidad validada por SKU y ubicación	Fuentes accesibles, responsables definidos y conciliación explicable.
Integración analítica	Históricos y productos de información	Calidad, claves y cobertura aceptadas por los responsables de negocio.
Consumo operacional	Señales utilizadas en una decisión	Vigencia visible, usuario responsable y actuación registrada.

La secuencia técnica parte de configuración, identidades, tópicos, almacenamiento y validación reproducible. Después incorpora eventos, transformaciones y consumo. Se requiere resolver el acceso a las fuentes, las equivalencias, la responsabilidad operativa y la decisión sobre servicios administrados antes de ampliar el alcance. La figura 20 resume las fases y condiciones de avance mediante evidencia de funcionamiento.

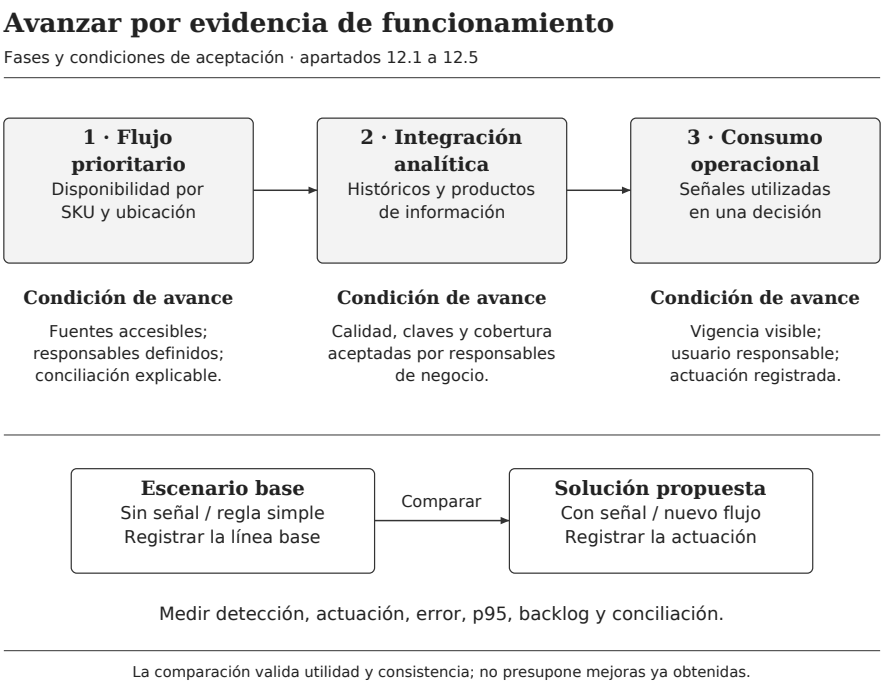

Figura 20: Fases de implementación y validación mediante evidencia de funcionamiento.
Fuente: Síntesis visual del contenido del informe y del diseño aprobado.

13.5 Experimentos contra el escenario base

Tabla 18: Experimentos y reglas para decidir

Experimento	Métrica	Criterio de decisión
Bajo stock con y sin señal	Tiempo de detección y de actuación	Confirmar utilidad operativa, sin atribuir ejecución automática.
Duplicados y datos tardíos	Conteos, orden lógico y salidas	No repetir efectos equivalentes; explicar descartes.
Plan diario frente a regla simple	Error y tiempo de cálculo	Incorporar complejidad solo si aporta mejora consistente.
Pico y caída de procesamiento	Tiempo de respuesta, backlog y recuperación	Cumplir objetivos acordados y conciliar datos recuperados.

Capítulo

14
Conclusiones y próximos pasos

14.1 Correspondencia entre solución y problemática

La propuesta integra la información que hoy se presenta fragmentada y la organiza para decisiones verificables. El enfoque híbrido atiende riesgos inmediatos sin exigir cómputo continuo a toda la analítica. La separación de capas conserva evidencia y prepara consumo, mientras los sistemas operativos mantienen responsabilidad de reservas, pagos y despacho. El valor se concreta cuando un responsable utiliza el resultado y su actuación mejora el servicio y la eficiencia operativa.

14.2 Decisiones adoptadas, riesgos y asuntos pendientes

Se mantienen integración por claves sustentadas, datos públicos independientes, escenarios sintéticos controlados y una base regional de GCP. Deben cerrarse la decisión sobre servicios administrados, el histórico inicial, sus correspondencias y la residencia definitiva. Latencias y recuperación requieren validación. El riesgo de adopción se reduce con una señal vigente, una cola de atención y registro de la decisión; una arquitectura funcional sin actuación no demuestra beneficio.

14.3 Prioridades para la siguiente etapa

La prioridad es completar un recorrido de inventario y pedidos antes de expandir usos. Se preparará infraestructura reproducible, se probará evento por evento y se incorporará el pipeline con conciliación. Luego se añadirán batch, estructuras de consumo y exposición. Se recomienda revisar resultados con operaciones y ajustar umbrales antes de automatizar actuaciones o incorporar modelos que aumenten la complejidad operativa.

Fuentes técnicas y de datos

[1] Google Cloud. *What is Pub/Sub?* https://docs.cloud.google.com/pubsub/docs/overview.

[2] Apache Software Foundation. *Beam Programming Guide*. https://beam.apache.org/documentation/programming-guide/.

[3] Google Cloud. *Exactly-once in Dataflow*. https://docs.cloud.google.com/dataflow/docs/concepts/exactly-once.

[4] Olist. *Brazilian E-Commerce Public Dataset*. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

[5] Chen, D. (2015). *Online Retail*. UCI Machine Learning Repository. DOI: 10.24432/C5BW33. https://archive.ics.uci.edu/dataset/352/online+retail.

[6] Google Cloud. *BigQuery meets Google ADK and MCP*. Descripción del origen sintético de theLook. https://cloud.google.com/blog/products/ai-machine-learning/bigquery-meets-google-adk-and-mcp.

[7] Equipo de RetailSmart Global. *Modelo de la Arquitectura de Solución de Lumina Retail. Vistas AS-IS y TO-BE*. Modelo representado con notación ArchiMate.

Anexos

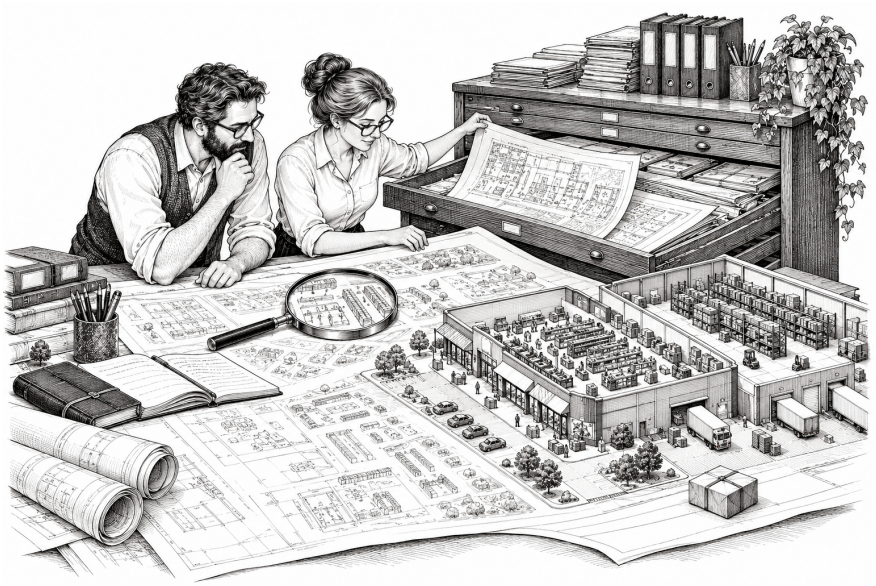

A Matriz de fuentes, verticales, componentes e indicadores

Tabla 19: Trazabilidad de las fuentes al resultado

Fuente o evento	Vertical	Componentes principales	Indicador o comprobación
Clics y pedidos	V1, V3	Captura, curación y Gold	Demanda; conversión solo si existe atribución válida.
Stock y catálogo	V1, V2	Streaming, Silver y señales	Vigencia y oportunidad de riesgo de quiebre.
Histórico de ventas	V2, V3	Batch, Silver y Gold	Plan diario y conciliación.
GPS y envíos	V1, V3	Streaming y Gold	Avance y tiempo de entrega.
Telemetría frigorífica	V4	Streaming y señales	Detección de condición anómala.
Sensores de almacén	V4, V1	Streaming y datos curados	Condición y oportunidad de actuación.

Regla de integración. Toda correspondencia conserva fuente, identificador de origen, clave del escenario y versión del mapa. La ausencia de equivalencia es un resultado de calidad que debe permanecer visible.

B Contratos de eventos y diccionario de datos

B.1 Perfil semántico mínimo propuesto

El cuadro define conceptos necesarios para validar la solución. Los nombres y tipos de los contratos vigentes del repositorio prevalecen. Este anexo no constituye una modificación de dichos contratos.

Tabla 20: Diccionario semántico de trazabilidad

Concepto	Significado	Control previsto
Identificador del evento	Identidad estable del hecho publicado	Mantenerla durante reintentos.
Tipo y versión	Evento definido y versión de contrato	Rechazar incompatibilidad no prevista.
Tiempo de ocurrencia	Momento en la fuente	Distinguirlo de la recepción.
Tiempo de ingesta	Momento de llegada a la plataforma	Medir demora y frescura.
Fuente e ID de origen	Sistema y registro que originan el dato	Permitir reconstrucción y linaje.
SKU y ubicación	Producto y punto operativo	Validar referencia y granularidad.
Pedido o envío	Identidad de la ejecución logística	Relación explícita con tracking.
Activo y medición	Equipo observado, valor y unidad	Validar rango, unidad y pertenencia.
Escenario o lote	Ejecución de prueba o carga histórica	Repetibilidad y conciliación.

B.2 Ejemplo ilustrativo de evento de inventario

El ejemplo no sustituye el esquema aprobado. Los campos del payload y sus nombres deben ajustarse al contrato del repositorio antes de implementar un productor.

```
{
  "event_id": "evt-stock-000123",
  "event_type": "stock_event",
  "schema_version": "1.0",
  "event_time": "2026-10-21T12:00:00Z",
  "source_system": "synthetic_inventory",
  "scenario_id": "normal-001",
  "payload": {
    "sku": "SKU-001",
    "location_id": "LOC-001",
    "quantity": 8
  }
}
```

La prueba espera que un umbral configurable de diez unidades produzca una señal de riesgo cuando corresponda. La misma identidad repetida no debe generar una actuación equivalente adicional. El dato analítico no reserva unidades ni garantiza reposición.

C Catálogo y nomenclatura de recursos

C.1 Convenciones de identificación

Se propone el patrón lógico `<proyecto>-<entorno>-<dominio>-<tipo>-<proposito>`. El identificador del componente permanece independiente del nombre físico. Se usan minúsculas y abreviaturas documentadas; BigQuery y otros servicios adaptan la sintaxis a sus restricciones. En buckets se requiere un sufijo que garantice unicidad. Los ejemplos siguientes son referencias de diseño, no un inventario de recursos desplegados.

Tabla 21: Catálogo lógico inicial para revisión

Componente ID	Elemento y servicio	Alcance y capa	Referencia de nombre
RS-STR-001	Tópico Eventos Retail; Pub/Sub	Global; sin capa	`rs-dev-str-ps-events`
RS-STR-002	Tópico Insights Retail; Pub/Sub	Global; sin capa	`rs-dev-str-ps-insights`
RS-DATA-001	Bronze Eventos Raw; Storage	Regional; Bronze	`rs-dev-data-gcs-bronze-<sufijo>`
RS-DATA-002	Silver Eventos Curados; Storage	Regional; Silver	`rs-dev-data-gcs-silver-<sufijo>`
RS-DATA-003	Gold Insights Retail; BigQuery	Ubicación configurada; Gold	`rs_dev_gold`
RS-SEC-002	Cuenta de aprovisionamiento; IAM	Global; sin capa	`rs-dev-sec-sa-deployer`

Los identificadores y nombres deberán cotejarse con el catálogo Git antes de un despliegue. El staging, las suscripciones y la cuenta de ejecución se incorporan con su definición aprobada; no se completan aquí con identificadores inventados.

C.2 Labels y atributos

Los atributos comunes incluyen proyecto, entorno, dominio, responsable y gestión por script. El detalle de verticales se conserva en el catálogo; un recurso compartido puede usar `vertical=multi` cuando proceda. El atributo `layer` se reserva para Bronze, Silver o Gold y `role` describe ingesta, consumo, función técnica o seguridad. Alcance global y política de residencia se documentan por separado.

D Detalle del costeo GCP

Este anexo concentra la matriz que alimenta el visor web de costos. Los valores corresponden al escenario base de planificación; el escenario conservador aplica 1,8× y el de máxima demanda 2,5×. Las tarifas deben contrastarse con la configuración vigente de Google Cloud antes de contratar capacidad.

Tabla 22: Matriz resumida de servicios y supuestos de costeo

Servicio	Grupo	Capacidad base	Unidad de cobro	Costo base mensual
Pub/Sub	Ingesta	51.84 M eventos/mes	USD/TiB	USD 5.41
Dataflow + Beam	Streaming	2 workers; 4 vCPU; 15 GiB	vCPU, memoria, Engine	USD 492.72
Cloud Storage + Parquet	Data Lake	74.2 GiB Bronze; 37.1 GiB Silver	GiB-mes	USD 2.22
BigQuery	Gold y analítica	2 TiB consultados/mes	TiB procesado + storage	USD 6.36
Cloud Logging	Observabilidad	80 GB logs/mes	GB ingerido + retenido	USD 260.00
Cloud Monitoring	Observabilidad	300 GB métricas/mes	métricas + alertas	USD 180.00
Persistent Disk	Dataflow	Discos temporales de workers	GB-mes + I/O	USD 120.00
Storage Transfer	Carga histórica	1 TB/mes	GB transferido	USD 75.00
Workflows	Batch	30 ejecuciones diarias	ejecución + pasos	USD 120.00
Dataproc	Batch	1 cluster; 40 h/mes	cluster-hora	USD 650.00
Cloud Run	API	2 M requests/mes	request + CPU	USD 280.00
Artifact Registry	Construcción	100 GB de imágenes	GB almacenado + red	USD 80.00
Dataplex / Knowledge Catalog	Gobierno	50 activos	activo + procesamiento	USD 220.00
KMS + IAM + DLP	Seguridad	10 llaves; 2 inspecciones	operaciones + inspección	USD 180.00
Looker	Consumo analítico	20 usuarios lectores	licencia + usuarios	USD 600.00
Total base mensual				**USD 3,271.71**
Máxima demanda (2,5×)				**USD 8,179.28**

La matriz es un resumen de planificación y no sustituye la cotización de GCP. La versión operativa y editable se mantiene en el visor web de costeo del proyecto.

E Vistas de la Arquitectura de Solución

Las siguientes láminas representan vistas del modelo de solución y permiten revisar la topología y la correspondencia entre componentes. Se elaboraron con notación ArchiMate. La exportación detallada contiene etiquetas pequeñas; la tabla 6 y la figura vectorial 9 proporcionan una lectura tipográfica de los componentes. Para una edición o impresión de gran formato conviene volver a exportar el modelo original a SVG o PDF.

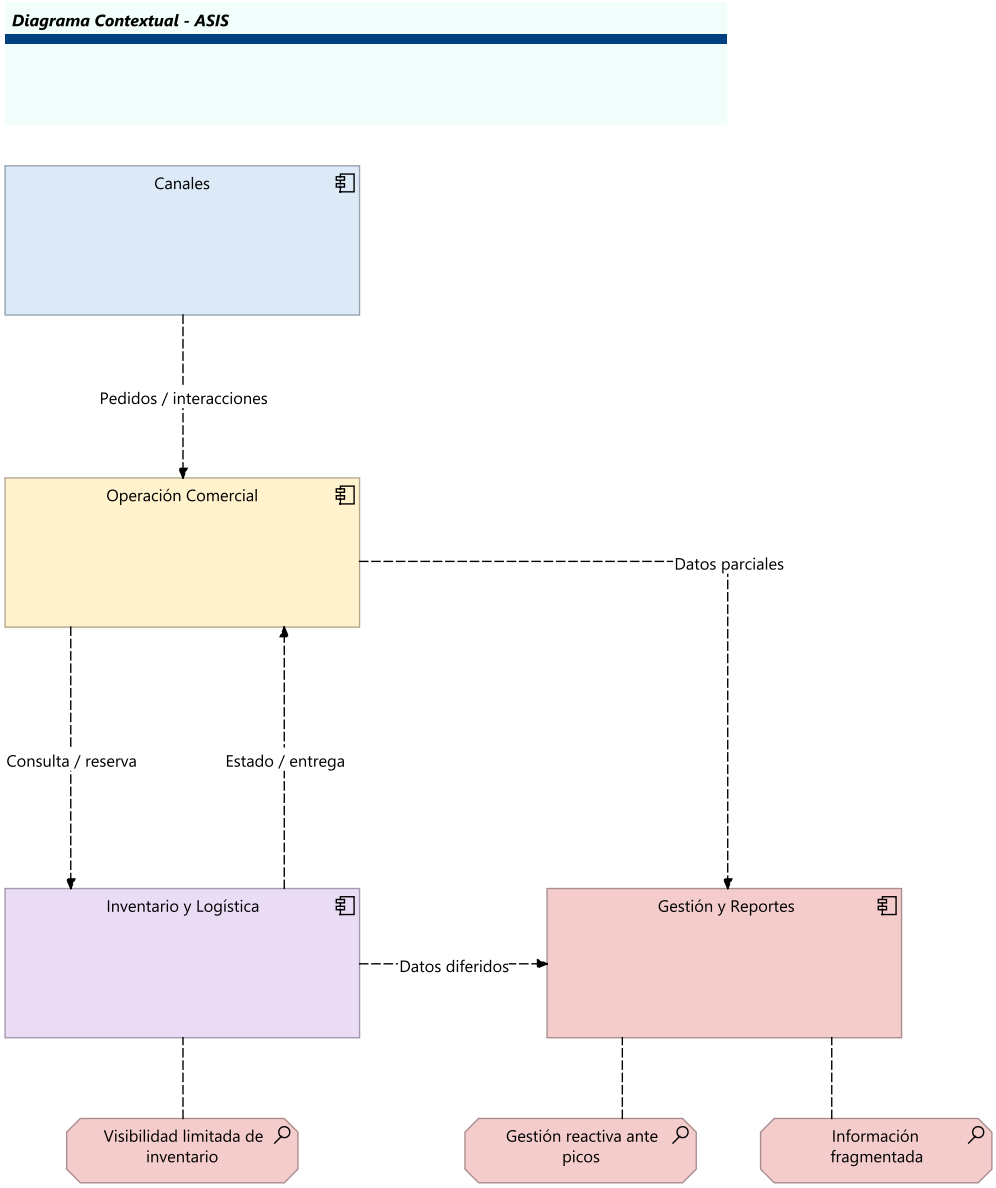

Figura 21: Vista contextual AS-IS de extremo a extremo

Fuente: Modelo de solución elaborado por el equipo [7].

Contexto de la solución propuesta

Diagrama Contextual - TOBE

Los sistemas actuales continúan operando el negocio. La nueva Plataforma de Datos recibe información de esos sistemas, la integra y procesa, y entrega información analítica para mejorar las decisiones.

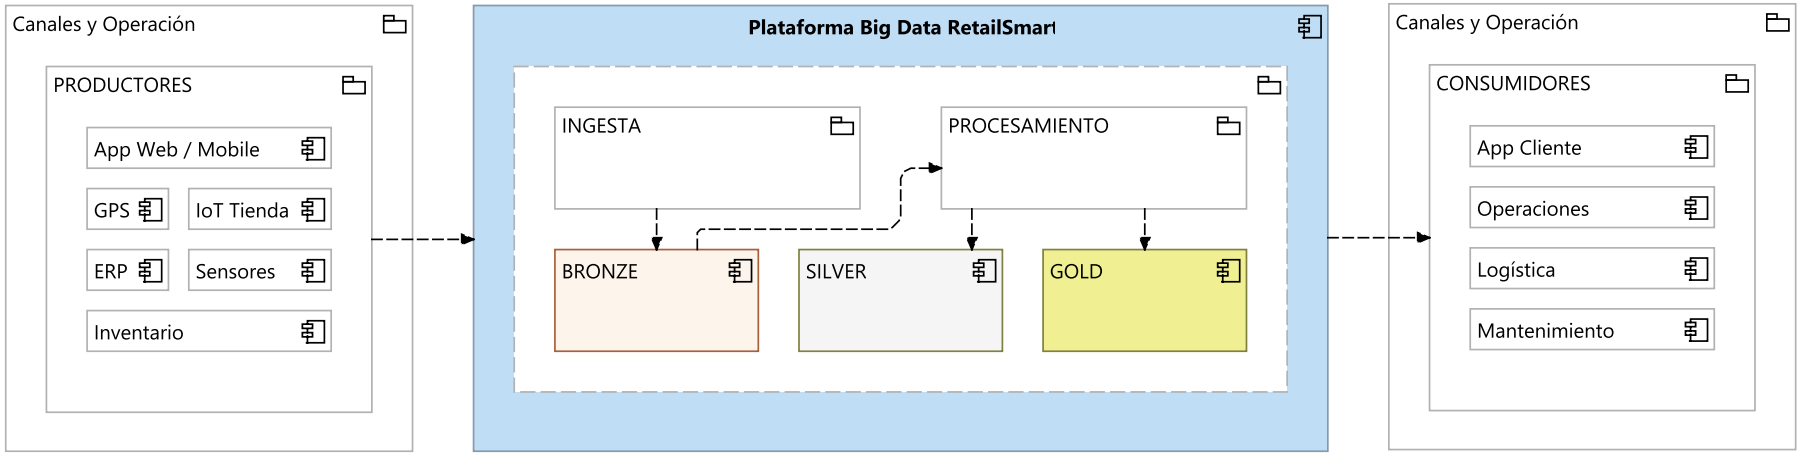

Figura 22: Vista contextual TO-BE de extremo a extremo

Fuente: Modelo de solución elaborado por el equipo [7].

Proceso actual de atención

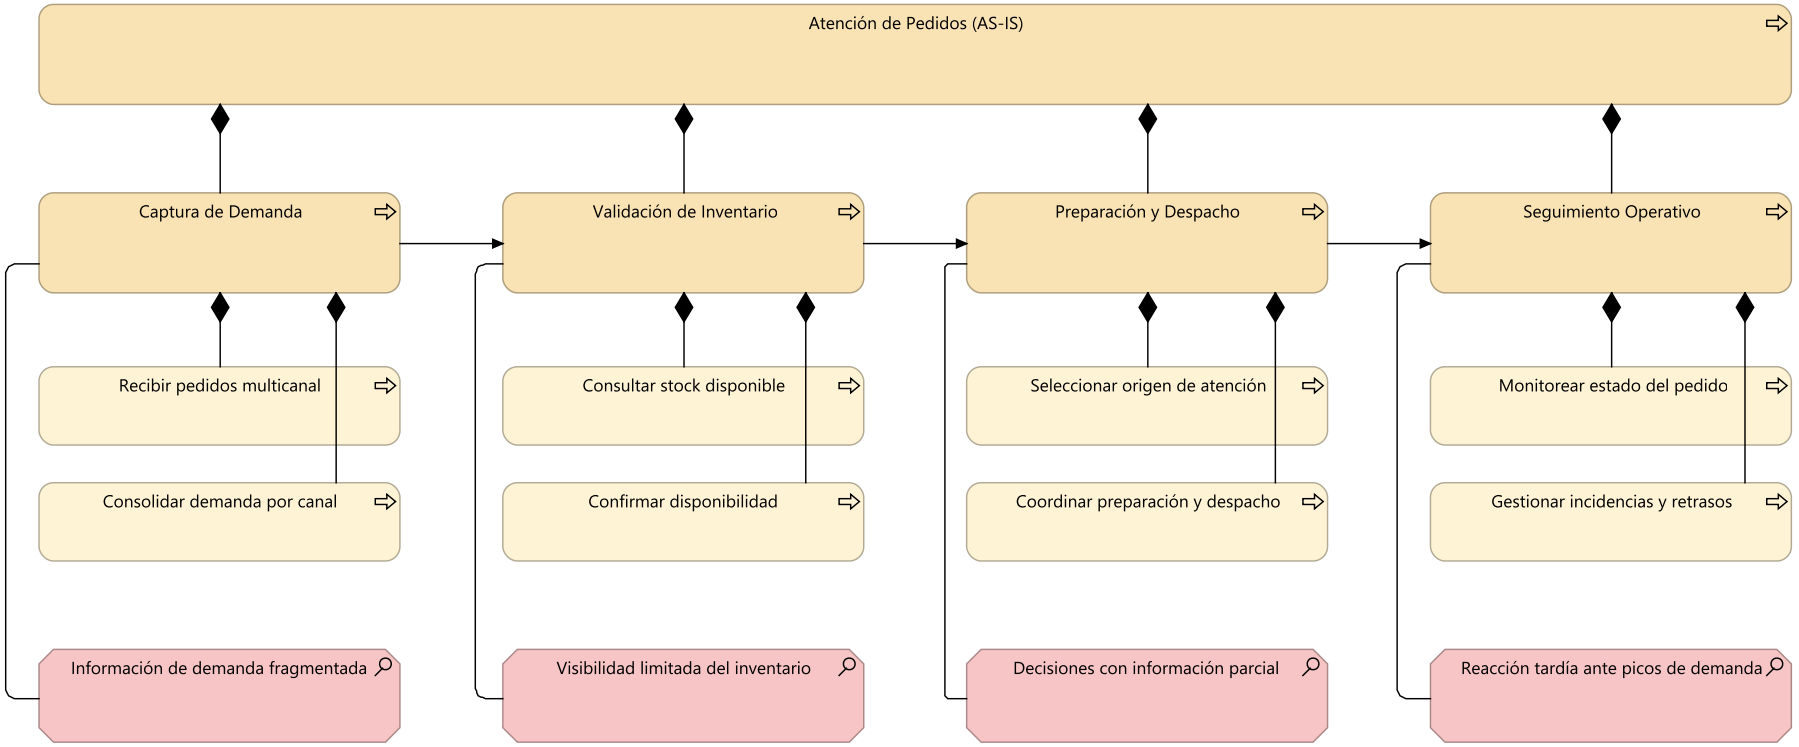

Figura 23: Vista completa de atención de pedidos AS-IS

Fuente: Modelo de solución elaborado por el equipo [7].

Proceso propuesto de atención

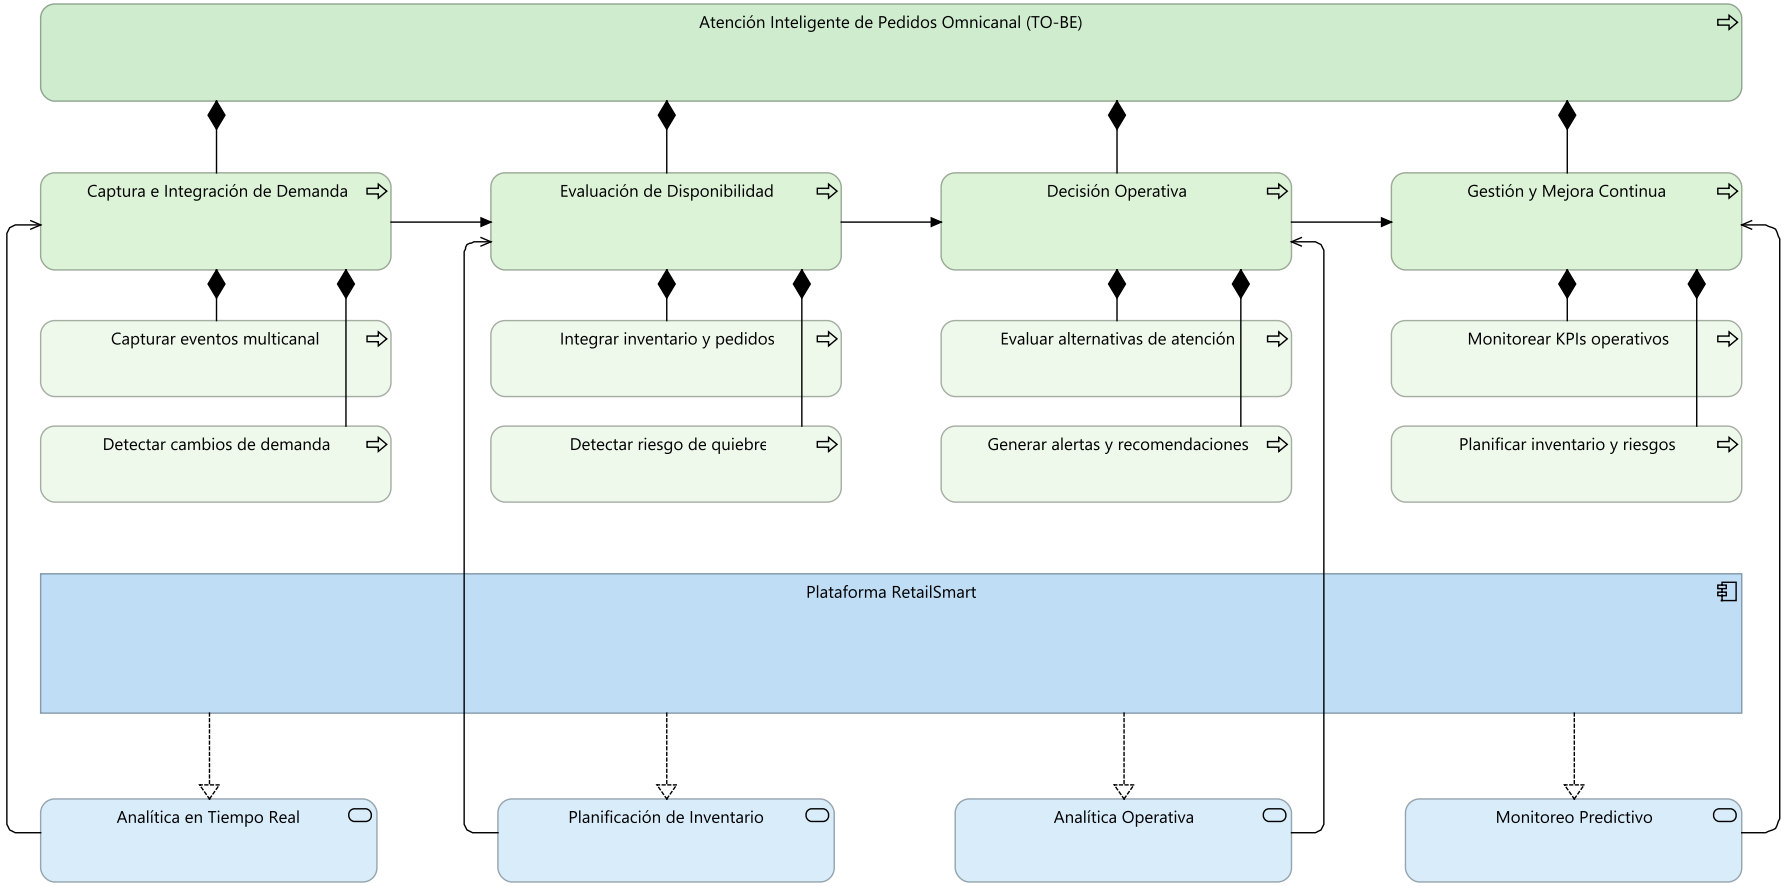

Figura 24: Vista completa de atención inteligente de pedidos TO-BE

Fuente: Modelo de solución elaborado por el equipo [7].

Aplicaciones y procesos actuales

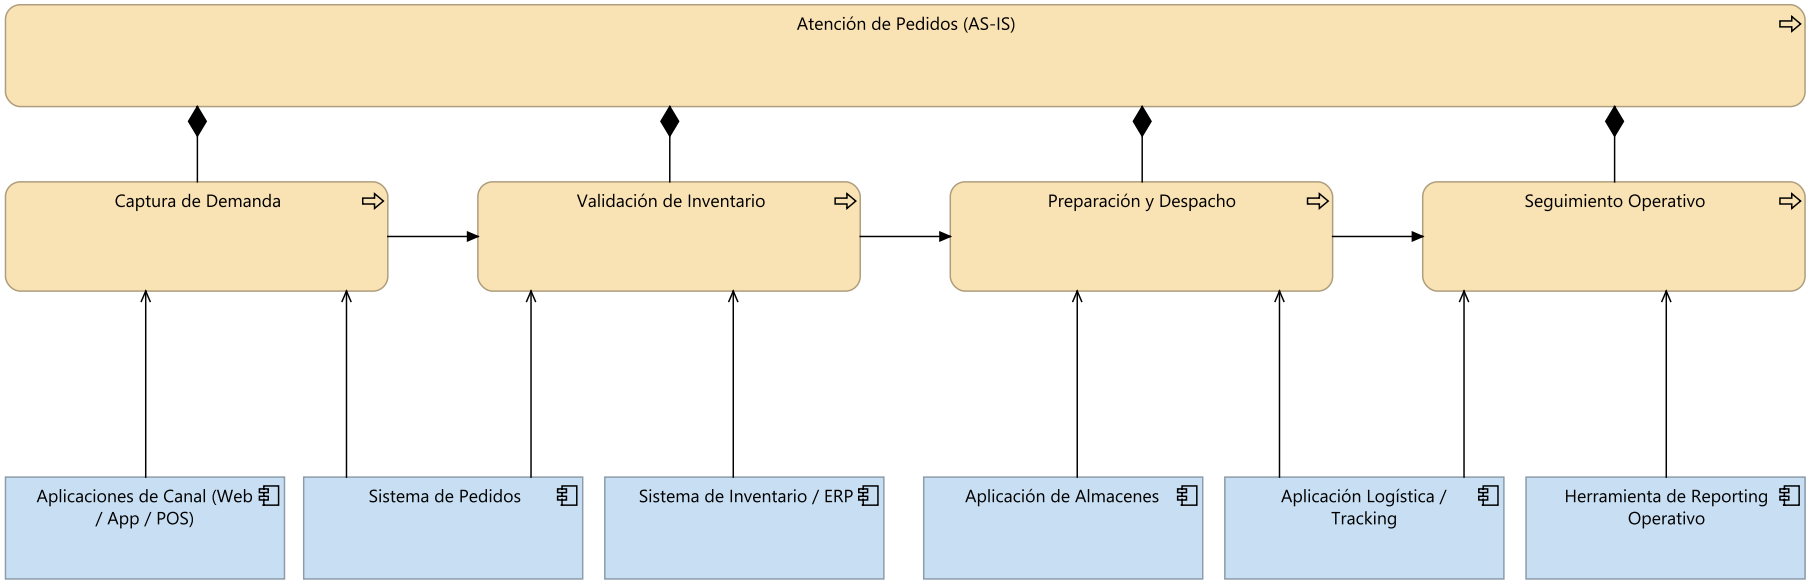

Figura 25: Relación entre aplicaciones y procesos AS-IS

Fuente: Modelo de solución elaborado por el equipo [7].

Aplicaciones y procesos propuestos

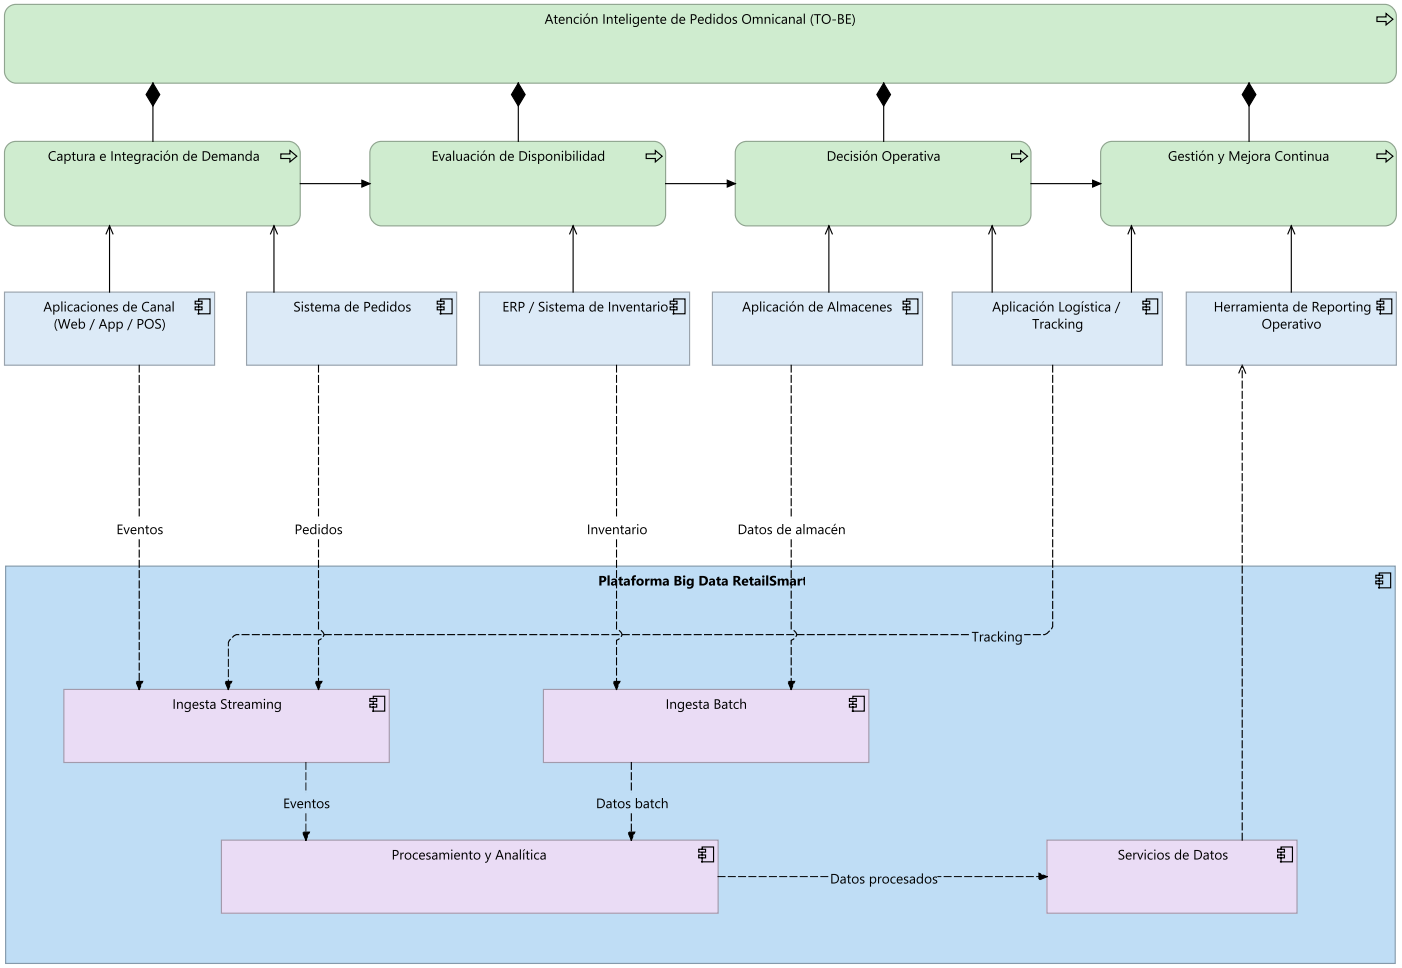

Figura 26: Relación entre aplicaciones y procesos TO-BE

Fuente: Modelo de solución elaborado por el equipo [7].

Integración macro de la solución

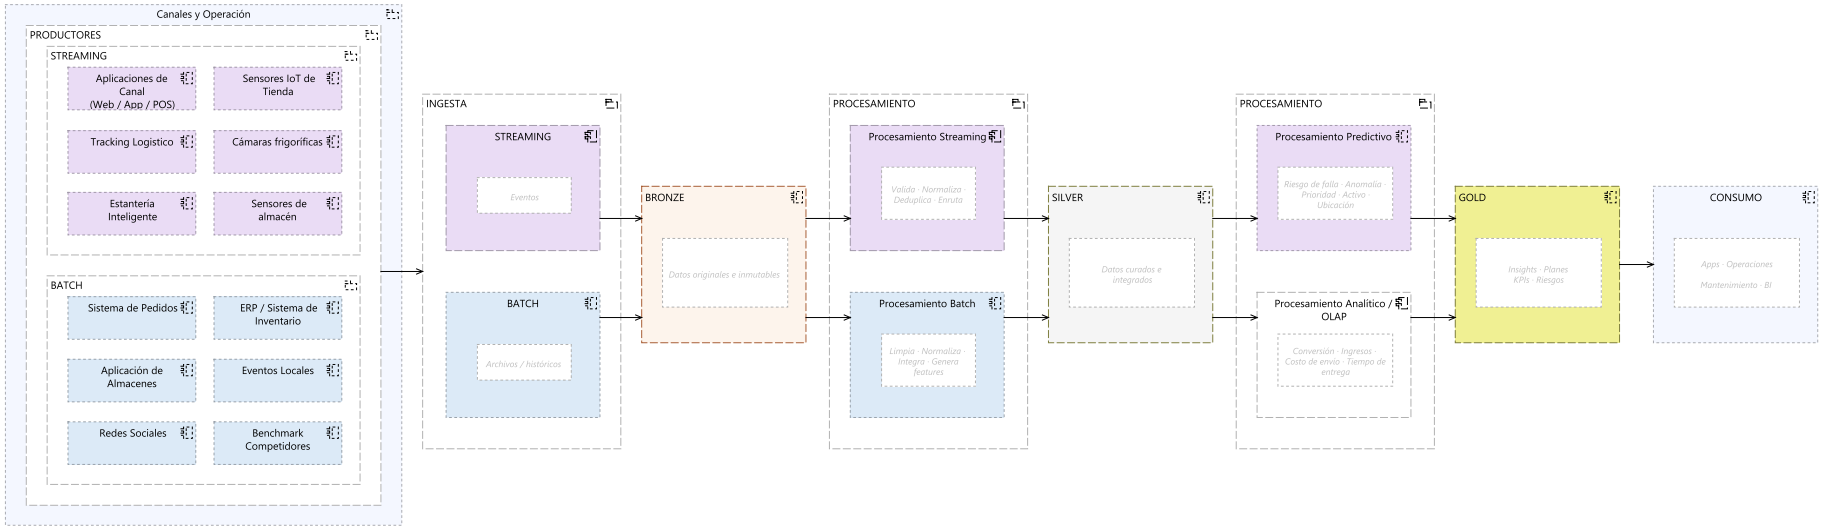

Figura 27: Vista macro de componentes e integración

Fuente: Modelo de solución elaborado por el equipo [7].

Modelo vigente de arquitectura de la solución

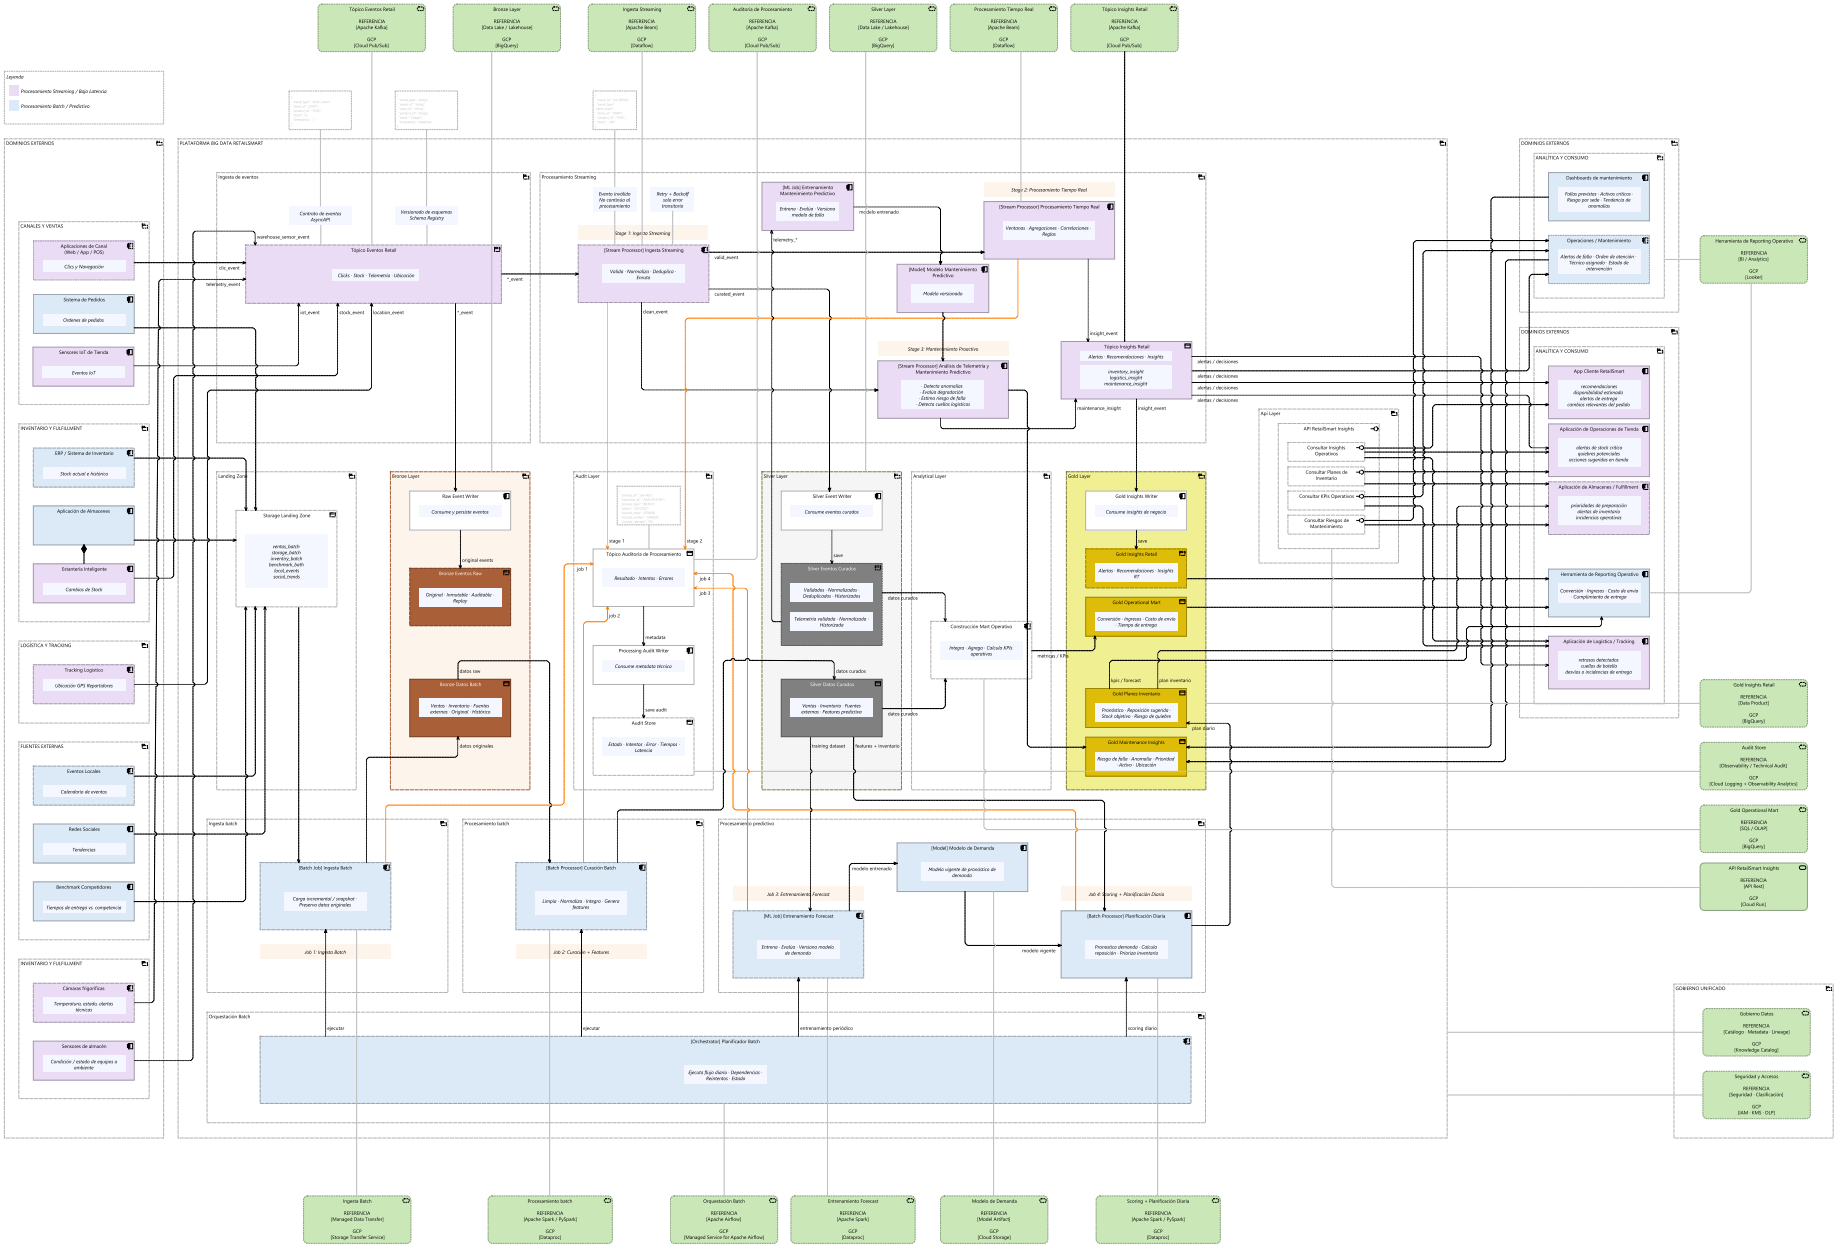

Figura 28: Modelo vigente de arquitectura de solución, exportado desde el archivo ArchiMate canónico.

Fuente: Modelo canónico de arquitectura del proyecto.